

Bio-ReRoute — 반증 우선 약물 재창출 에이전트

연구 · 기술 보고서

제4회 AI 신약개발 경진대회 · 공모분야 1 「자율형 가설 생성 및 검증」 황승우 (1인) · 2026년 9월 · 코드 `bioreroute-v69.zip` · 회귀 시험 2599건

- 데모 — <https://james7371-bio-reroute.static.hf.space> (키 없이 열린다 · 판정은 미리 구워 둔 스냅샷이다)
 - 코드 — <https://github.com/hwangjames7371/Bio-ReRoute-public> (제출 시점 사본 · 코드 · 봉인 명세와 제3자 타임스탬프 · 결과 파일 · 결함 대장)
-

0. 요약

생성형 AI 는 약물 재창출 후보를 **만드는 비용**을 거의 0으로 만들었다. 남은 병목은 그럴듯하지만 틀린 후보를 값싸게 걸러내는 일이다[4]. Bio-ReRoute 는 그 일만 한다 — 가설(약물 · 질환)을 받아 공개 문헌 · 임상 등록부 · 화학 정보에서 **반증을 먼저 찾고**, 근거가 모자라면 판정하지 않고 **보류**한다. 판정마다 근거 문장 원문 · PMID · 가중치를 남긴다.

평가는 «얼마나 잘 찾았나» 가 아니라 **기각이 맞았나 · 맞는 것을 버렸나 · 신뢰도가 정직한가**로 한다. 사전 기준이 있는 실험은 모두 결과를 보기 전에 기준을 적고 해시로 봉인한 뒤 돌렸고, 그 밖의 분석은 **사후**라고 표시했다.

	결과
본선 홀드아웃 774쌍 (실패 임상 387 · 승인 적응증 387 · 봉인 · 두 번째 개봉 · gpt-5.6-terra)	기각 정밀도 94.3% (99/105) · 성공한 약을 버림 1.6% (6/387) · «모른다» 61.1%
같은 모델을 문헌 없이 쓴 기준선(모델 단독)과 비교	전체에서는 모델 단독이 더 거른다(정밀도 96.8% · 재현율 31.5% 대 25.6%) — 우위를 주장하지 않는다 . 모델이 «모름» 이라 답한 445쌍(정의상 모델 단독은 거르지 않는다 · 실패 비율 44.7%)에서 파이프라인이 41건을 기각해 38건 적중(사후)
보정 (Brier · 낮을수록 좋다)	파이프라인 0.219 · 모델 단독 0.218 · 널 0.250 (774쌍). 개발집합으로 맞춘 Platt 보정 후 파이프라인 0.220 → 0.212(개발집합과 겹치는 4쌍을 뺀 770 쌍). 모델 단독과는 구별되지 않는다
인용 검증 (본선 실행 전수)	검사한 인용 2,129건 중 2,128건이 초록 원문에 실재(99.95%) · LLM 이 낸 인용 중 쓸 수 있던 것은 32.0%
전향 봉인 예측	결과가 아직 없는 임상 60건 + 무작위 음성대조 20쌍 봉인(개발 단계 모델) · 음성대조에 «유망» 0/20
사전명세	31회 봉인 · 사전 기준 42개 — 통과 20 · 미달 14 · 판정 불가 8 · 결과를 본 뒤 기준을 낮춘 기록은 없다
스스로 찾은 결함	결함 369건 공개(측정 · 문서 · 절차) · 회귀 시험 2599건

가장 중요한 한 줄 — 우리는 반증하는 시스템을 만들었고, 그 절차를 우리 자신의 측정에 먼저 적용했다. 이 보고서의 수치 가운데 상당수는 그 절차가 우리 주장을 **깎은** 결과다.

개발 이력 — 예선 기획서를 준비하던 7~8월에 프로토타입을 만들었다. 본선 기간(9월 7일~10월 2일)에는 주최측 모델로 옮기고, 봉인 홀드아웃을 그 모델로 다시 켜고, 전문 읽기를 새로 만들고, 결함을 고치고 검증했다. 이 보고서의 수치는 본선 모델로 켜진 것이 기본이고, 개발 단계 모델로 켜진 것은 그렇게 표시했다.

1. 문제

1.1 병목은 후보가 아니라, 틀린 후보를 버리는 일이다

임상에 진입한 신약의 약 86%가 승인에 실패하고[1], 2·3상 실패의 사유는 효능 52% · 안전성 24%다[2]. 재창출은 안전성이 이미 확인된 약에서 출발하므로[6] 남는 병목이 정확히 **효능**이다.

틀린 가설 하나의 비용은 실측된다. 2020년 2~11월 하이드록시클로로퀸(HCQ)으로 코로나19를 치료하려는 시험이 NIH 등록부에만 **206건** 등록됐다. 11월 기준 135건이 진행 중, 22건이 완료, 46건이 중단·종료였고, 저자들은 의료계가 정치적 관심에는 빨리, 효능이 없다는 근거에는 늦게 반응했다고 결론 지었다[3].

이 문제 정의는 우리 것이 아니다. Maziarz & Stencel 은 같은 HCQ 사례로 코로나 재창출의 실패를 과도한 가설 검정과 약한 기전 근거로 설명하고, 음성(반증) 기전 근거를 함께 보라고 처방했다[4]. 우리 몫은 그 처방을 후보마다 자동으로 실행하는 절차로 만들고, 그 절차가 얼마나 맞는지 미리 정한 기준으로 잴 것이다.

1.2 반증 근거는 얼마나 있는가 — 두 숫자

ClinicalTrials.gov 의 종료 시험 34,067건을 같은 분류기로 전수 분류했다(LLM 0회).

종료 시험 전수	34,067	
운영상 중단 (모집 · 자금 · 공급 · COVID)	16,224	47.6%
사유 불명 · 미기재	13,745	40.3%
약물 개입 없음	2,198	6.5%
안전성 중단	455	1.3%
효능 실패로 중단	1,445	4.2%
<- 그중 대조 가능(무작위 · 2상 이상) 781 (54%) -> 전체 대비 2.3%		

종료 시험 100건 중 반증에 쓸 수 있는 것은 2건이다. 중단 사유가 자유 기술이라 4.2%는 하한이다.

그런데 누군가 실제로 제안하는 후보에서는 다르다. LLM 이 제안한 후보를 같은 도구로 재면 —

	무작위(대조 가능) 독립 시험이 있는 쌍의 비율	그 약들의 문헌 중앙 값
LLM(개발 단계 모델)이 제안한 후보 14 쌍	79% (11/14) [52-92]	259
홀드아웃 TN 384쌍 (조회 실패 3 제외)	39% (150/384) [34-44]	9
개발 벤치마크 TN 42쌍	29% (12/42)	40

Fisher $p = 0.004$ · 검정력 88%. 생성기는 유명한 약을 내고, 유명한 약에는 시험이 있다.

⚠ 이 대조는 사전 지정이 아니다. 2.3%를 본 뒤에 다른 분모로 다시 재서 찾은 값이다. 이 보고서에 는 이런 탐색적 검정이 여럿 실려 있어, $p = 0.004$ 를 다중비교까지 건넌 확증으로 읽지 않는다 — 방향을 보여 주는 관찰로만 쓴다. 그래서 두 숫자를 같이 적는다 — 2.3%만 말하면 제안되는 후보를 감추고, 79%만 말하면 모집단을 감춘다.

1.3 그리고 근거는 늦게 온다

개발 벤치마크의 효능 실패 쌍에서 반박 문헌의 출판 시점을 대조하면 12건 중 11건이 시험 종료 이후에 나왔다. 판정에 쓸 문헌을 시험 종료 1년 전 · 3년 전까지로 막으면(시점 차단) 기각 재현율이 17% → 2% → 0% 로 무너진다 (개발 단계 모델 gpt-5.4-mini).

두 사실은 함께 참이다 — 반박 근거는 비싼 시험을 치른 뒤에야 생기고(11/12), 일단 생기면 유명한 약에 쌓인다(79%). 그래서 이 시스템이 하는 일은 새 약을 예언하는 것이 아니라, 이미 쌓인 반박을 지

금 제안된 후보에 되돌려 적용하는 것이다. 본선 홀드아웃에서 이 시간 구조를 다시 짰다(\$4.4).

2. 시스템

2.1 반증 깔때기 — 값싼 결정론부터

약자	관문	하는 일	LLM
F0	근거 실재성	약물 이름이 문헌에 있는가(실체) · 그 약물-질환 쌍에 문헌이 있는가(연결). 약물은 있는데 쌍 문헌만 없으면 기각하지 않고 신규성 신호 로 표시한다[19]	없음
L2	팩트체커	LLM 이 인용한 문장이 초록에 실제로 있는가 · 결과를 진술하는가 · 그 약을 지목하는가 → 지지·반박 방향과 가중치	사용
R	기전 라우터	직접/간접 × 병원체/숙주로 분류해 검증 경로 를 정한다 — 탈락이 아니라 분기다	사용
S1	구조 신뢰도	구조 경로일 때만 — AlphaFold pLDDT[15]. 결합력이 아니다	없음
S2	리간드 개발성	PubChem → RDKit: PAINS[13] · Ro5[14] · hERG · DILI 경고	없음
SK	회의주의자	반박 문헌을 능동으로 더 찾아 읽는다	사용
F	전문 읽기	논문 전문에서 저자가 스스로 적은 한계를 읽어 근거 가중치를 감쇠한다(지지 · 반박 양쪽)	사용
REG	등록부	ClinicalTrials.gov 에서 같은 약 · 질환의 실패 임상을 찾아 팩트체커로 읽는다	사용

값싼 관문을 통과한 후보만 비싼 단계(LLM)로 간다. 관문마다 켜고 끌 수 있어 **제거 실험이 반복문 하나**로 돈다.

구성	컨 것	쓰임
B0	없음 — 같은 모델에게 문헌 없이 «성공 · 실패 · 모름» 을 묻는다	모델 기억 기준선
B1 ~ B4	문헌 검색·팩트체커 → + F0 → + 회의주의자 → + S2	제거 실험
B5	문헌 검색·팩트체커 · F0 · 라우터 · S2 · 회의주의자	평가 구성 — 이 보고서의 주 수치
B6	B5 + 등록부	등록부 실험
B7	B6 + S1	벤치마크에 쓰지 않았다
B8	B7 + 전문가 거절 목록(HITL)	운용 구성 — 재현 가능한 측정이 아니라 벤치마크에 쓰지 않는다
B5F	B5 + 전문 읽기	전문 읽기 실험(§4.3 · 판정 불가)
B5SF	B5 + S1 + 전문 읽기	시연 구성 — 데모가 쓰는 것

평가 구성 B5 에는 S1 · 등록부 · 전문 읽기가 없다. 넣으면 봉인된 수치가 다른 시스템의 수치가 되므로 따로 잰다(§4.3).

2.2 판정 — 로그오즈를 쌓고, 모르면 기권한다

판정 확률은 규칙 기반 로그오즈 합이다 — LLM 이 확률을 직접 정하지 않는다. 다만 근거 한 건의 가중치는 연구 유형과 LLM 이 매긴 등급(규모 · 결정성 · 확신 · 확실성), 인용 검증 결과를 곱해 정하므로 LLM 은 등급을 통해 무게에 들어간다 (같은 논문의 가중치가 실행마다 흔들리는 이유가 이것이다 · §4.7). 같은 시험의 본 논문 · 추적 · 하위분석(같은 NCT)은 한 번만 세고, 상관된 근거는 감쇠하며, 확신에는 상한을 둔다. 지지와 반박이 대등하면 기각하지 않고 조건부로 둔다.

로그오즈를 쌓지 않고 0%로 끊는 경우는 둘뿐이다 — ① 약물 이름 자체가 문헌에서 안 잡힐 때(F0 · 실제로는 임상시험 개입명이 코드나 용량 표기라 문헌 검색에 안 걸리는 경우가 대부분이다) ② 확증 임상의 결정적 음성이 두 건 이상이고 같은 급의 지지가 없을 때. 그 밖에는 근거를 쌓아 판정하고, 근거가 얇으면 보류한다. 근거 없이 기각하는 것은 반증이 아니라 사전확률이기 때문이다.

2.3 기전 라우터 — 언제 도킹하지 않는가

경로	예	타당한 검증
직접 · 병원체	RdRp 억제제	구조 신뢰도(S1) → 도킹 후보
직접 · 숙주	바리시티닙(JAK)	임상 · 발현 근거 — 바이러스 단백질 도킹은 무의미하다
간접	메트포르민(Complex I 억제 → AMPK 활성화[16])	네트워크 · 임상 근거 — 도킹은 범주 오류다
오프타겟 · 불명	—	근거 경로

이 전제는 우리 것이 아니다 — 감염을 실제로 줄인 약 77개 중 76개가 바이러스 단백질에 결합하지 않아 도킹으로는 찾을 수 없다[5]. 우리 몫은 그 판단을 **후보마다 자동으로 내리고, 안 돌린 이유를 판정 기록에 남기는** 것이다.

분기가 실제로 열리는지 봉인하고 졌다. 병원체 표적 8쌍(remdesivir/RdRp · nirmatrelvir/3CLpro ...)과 숙주 · 간접 8쌍(baricitinib/JAK · camostat/TMPRSS2 · maraviroc/CCR5 ...)을 섞었다. 대조군 8쌍 중 7쌍이 감염병(COVID-19 4 · HIV 2 · 말라리아 1)이라 «감염병이면 구조» 라는 지름길은 여기서 반드시 틀린다. 결과 — 병원체 **8/8** 구조 경로 · 숙주 · 간접 **0/8** · Fisher p = 0.0002(사전 기준 통과 · 봉인 해시를 실행 전에 제3자 타임스탬프로 등록했다 · 개발 단계 모델 · 온도 0).

그리고 통과한 쪽마저 자료가 거부했다. 라우터가 구조 경로로 보낸 8건과 규칙을 통과한 maraviroc 1건에 실험 구조를 대 보니 **9/9 가 도킹 불가**였다. 가장 흔한 사유는 «도킹할 분자가 그 자리에 오는 분자가 아니다»(전구약물 · 공유결합 부가체 · 4건)였고, 나머지는 자리 미형성 1 · 구조 자료 없음 3 · 포켓 정의 불가 1 이다. **도킹은 한 번도 돌리지 않았고, 그것이 결과다.**

S1(pLDDT)은 **필요조건**으로만 쓴다 — 도킹 성능이 가장 크게 떨어진 AlphaFold 모델 다섯 중 넷에서 결합 부위 잔기의 pLDDT 가 모두 70 이상이였다는 보고가 있다[10]. 활성부위 주석이 없는 표적은 단백질 전체 평균을 쓰고, 그것이 약한 대리물이라고 화면이 적는다.

2.4 인용 검증 3겹 — 그리고 감사 추적

LLM 이 근거로 든 문장마다 셋을 확인한다.

	확인	아니면
①	그 문장이 초록 원문에 실제로 있는가	무관으로 강등(가중치 0)
②	그 문장이 결과를 진술하는가	감쇠
③	그 문장이 그 약을 지목하는가	감쇠(간접 근거)

실제 사고 셋이 이 관문을 만들었다 — `interferon beta-1a` / `크론병` 이 **natalizumab** 메타분석을 근거로 «유망 94%» 를 받았고, `pramipexole` / `ALS` 가 거울상체 **dexpramipexole** 의 3상을 근거로 삼았고, «측

정 방법» 같은 문장이 높은 가중치로 채택됐다. **셋 다 실재하는 문장이었다.** 지어낸 것이 아니라 **관계가 틀렸다.**

판정은 숫자 하나로 끝나지 않는다. 화면과 결과 파일에 **근거 문장 원문 · PMID · 연구 유형 · 가중치 · 관문별 결과**가 남고, 산출물에는 **AI 생성 표기**와 분업(후보 · 요약 · 기전 분류 · 근거 등급은 LLM · 인용은 원문 대조를 통과한 것만 · 확률은 규칙 기반 합)이 붙는다. 틀렸을 때 **어디서 틀렸는지** 그 자리에서 보이게 하는 것 — 감사 추적이 이 시스템의 본체다.

2.5 자율성 — 오류를 알아채고, 고칠 수 있으면 고친다

고친다	알아채고 판정을 멈춘다
인용이 초록에 없다 → 가중치 0	PubMed 조회 실패 → 보류(0건으로 세지 않는다)
인용이 다른 약을 가리킨다 → 감쇠	AlphaFold 응답 없음 → 경로를 바꾸지 않는다
같은 시험의 본 논문 · 추적 · 하위분석 → 시험 번호 (NCT)로 하나만 센다	부작용 신호의 분모가 0 → 계산 불가(무한대를 신호로 쓰지 않는다)
지지 · 반박이 대등 → 조건부로 재분류	분류가 전부 실패 → 판단 자체를 거부(종료 코드 1)
근거가 철회됐다 → 근거에서 제외	

조회 실패를 0건으로 세면 네트워크 장애가 «발견» 이 된다. 실제로 한 도구가 조회 실패를 0건으로 합산해 «반증 근거의 부재는 구조적이다» 라는 결론을 낸 적이 있다 — 하필 우리 논지를 지지하는 방향이었다(§5). △ 이 방어가 F0 의 두 번째 조회(약물 실재 확인)에는 늦게 붙어, 본선 실행에서 1건이 조회 한도 초과(HTTP 429) 인데도 «문헌 없음» 으로 기각됐다 — §4.1 의 기각 105건에 들어 있다(실행 뒤 고쳤다 · 결함 대장 329번). 메타분석은 시험 번호가 없어 위의 중복 제거에 걸리지 않는다(§5).

하지 않는 것도 적는다. 실패한 뒤 전략을 새로 짜는 **자율 재계획은 없다.** 라우터가 후보별로 검증 경로를 고르는 것이 계획의 전부다. 궤적을 세어 보니 «관문을 스스로 건너뛴다» 로 보이던 기록의 대부분 (개발집합 실행에서 건너뛴 88건 중 84건)은 **설정에서 끈 것이었다** — 계측을 고쳐 돌을 나눠 남긴다. 전문가 거절 목록(HITL)은 코드가 있지만 평가할 전문가가 없어 측정과 시연에서 껴다.

2.6 도구와 자료원 — 전부 공개 · 무료

자료원 · 도구	쓰는 곳
PubMed (E-utilities)	F0 · 팩트체커 · 회의주의자 · 시점 차단
ClinicalTrials.gov API v2	등록부 · 종료 시험 34,067건 전수 분류 · 정답표(TN)
RepoDB[17]	정답표(TP · 승인 적응증)
PubChem → RDKit	S2 개발성(PAINS · Ro5 · hERG · DILI 경고) · 분자 지문
UniProt → AlphaFold DB	S1 구조 신뢰도(pLDDT) · 3Dmol.js 구조 표시(색은 예측 신뢰도이지 결합력이 아니다)
RCSB PDB · UniChem	실험 구조 · 종 대조(도킹 가능 여부 판단)
openFDA FAERS · SIDER	역발상 발굴(부작용 신호)
ChEMBL · SureChEMBL	저분자 한정 · 관련 특허 검색(자유실시 판단이 아니다)
DRKG	그래프 검색(라이선스 CC BY-NC)

외부 조회가 살아 있는지는 `netcheck` 가 LLM 0회로 확인한다. RDKit 이 없으면 S2 는 **SKIP** 으로 표시된다 — 숨기지 않는다.

2.7 모델 선택 — 왜 `gpt-5.6-terra` 인가

주어진 선택지. 본선 크레딧은 `gpt-5.6-sol` · `gpt-5.6-terra` · `gpt-5.6-luna` 셋을 지원했다. 개발 단계에 쓰던 `gpt-5.4-mini` 는 이 크레딧으로 쓸 수 없다. `gpt-6` 계열 둘은 주 평가 실행 뒤에 추가돼 쓰지 않았다.

판정 성능으로 고르지 않는다. 여러 모델로 벤치마크를 돌려 가장 잘 맞는 것을 고르면 결과를 보고 시스템을 고른 것이 된다. 그래서 고르는 규칙을 실측 전에 명세에 적었다(사전명세_모델교체_본선.md §4) — **0단계 자격:** JSON 형식 준수 90% 이상 · **1단계 순위:** ① 응답 지연 중앙값 → ② 출력 토큰량 → ③ 이름순. 판정용이 아닌 형식 확인 프롬프트로 모델당 30회를 두 차례에 나눠 잤다.

모델	JSON 준수	지연 중앙(초)	출력 토큰(20회 합)
sol	20/20	2.12	375
terra	20/20	1.89	359
luna	20/20	1.74	635

셋 다 자격을 통과했고, 지연은 terra 와 luna 를 가르지 못했다(순열검정 $p = 0.543$). 그래서 ②로 내려가 **terra** 의 출력 토큰이 luna 의 1/1.77 이었다. sol 에는 ① · ② 둘 다 앞섰다.

뒤에詹 것도 같은 쪽이었다. 세 모델 모두 `temperature=0` 을 거부해 재현성을 따로 잤다 — 같은 질문을 다섯 번씩(소수 · 분류 · 자유 요약) 물었을 때 **terra** 만 세 유형 모두 다섯 번 같은 답이었다(sol 두 유형 · luna 한 유형). 그래서 `seed = 42` 를 고정해 쓴다(세 모델 모두 고정하면 5/5 · 보장이 아니라 재

현 시도다). 외부 공개 순위(IQ 시험)도 terra > sol > luna 였지만, 등급 이름이 같은 물건인지 모르고 우리 과제와 구성 개념이 달라 참고로만 적는다.

⚠ **말하지 않는 것** — «terra 가 우리 과제에서 가장 정확하다» 는 재지 않았다. 규칙의 봉인(해시)은 선택 뒤에 걸려서, «실측 전에 적었다» 의 증거는 우리 기록뿐이다(§3.4). 그리고 그 명세는 **봉인 다음 날 본문에 문단을 덧붙여** 1차 봉인 본문을 되살릴 수 없다(다시 봉인하고 두 해시를 남겼다 · §4.3) — 이 명세로 낸 수치를 인용할 때는 이 사실을 같이 적는다. 사후에 네 모델을 같은 홀드아웃에 돌린 결과는 §4.1 이다 — «모름» 문항의 순위 지표는 모델 간에 구별되지 않았고, **기각 문턱은 모델마다 달랐다**. 모델을 바꾸면 문턱을 다시 맞춰야 한다.

2.8 리소스 — 크레딧은 살아남은 후보에만

	실측
본선 홀드아웃 774쌍 한 번 (B0 + B5)	523만 토큰 · 호출 1,093회 · 지원 한도(3,000만 토큰)의 17%
같은 774쌍 시점 차단 재실행	457만 토큰 · 호출 996회
단계별 토큰 (위 첫 실행)	팩트체커 292만 · 회의주의자 201만 · 라우터 15만 · 모델 단독 15만
LLM 0회로 낸 것	종료 시험 34,067건 분류 · 인용 충실도 · 판정 취약성 · 보정 · 정답표 감사 · 누출 측정 · 문서 감사
유료 데이터 · GPU	0원 · 0개 — 도킹을 돌리지 않는다
폭주 방지	실행당 LLM 호출 상한(기본 60회) · 라이브 실행 하루 300회 상한 · 토큰 계량기(우리가 직접 센다)
모델 교체	역할별 모델을 설정 한 줄로 바꾼다 — terra ↔ luna · sol 98쌍에서 검증 경로 불일치 각 1/98 · 같은 모델을 두 번 돌린 잡음(1/98 · 0/98)과 같은 수준 · 5분류 일치 κ 0.825 · 0.849 (명세는 §2.7 의 그것 — 봉인 뒤 본문이 고쳐졌다)

비용 대부분은 문헌을 실제로 읽는 두 단계(팩트체커 · 회의주의자)에 든다. 값싼 관문(F0 · S2 · 라우터 분류)을 앞에 두는 이유가 그것이다. 확장은 자료원이 어댑터로 분리돼 있어 새 DB 가 파일 하나이고, 새 구성은 설정 한 줄이다.

3. 평가 설계

3.1 원칙 — 무엇을 먼저 보나

1. **기각이 맞았나** — 기각 정밀도(기각한 것 중 실제로 실패한 약)
2. **맞는 것을 버렸나** — 승인된 약을 기각한 비율

3. **모르면 모른다고 하나** — 보류 비율과 Brier 를 **널 모형(늘 기저율)**과 나란히 적는다
4. **모델 기억이 아닌가** — 같은 모델을 문헌 없이 쓴 기준선(B0)을 같은 쌍에 나란히 적는다

AUROC 는 보조다. 시스템은 «보류» 로 기권하는데 AUROC 는 기권을 0.5 쪽으로 뭉개 정보를 버린다. ECE 도 쓰지 않는다 — 기저율이 0.5 인 평가 집합에서는 «늘 0.5» 라고 답하는 널 모형의 ECE 가 0 이다.

3.2 자료

집합	구성	쓰임
개발 벤치마크 (층 A)	TN 42 (효능 실패로 중단된 임상의 약-적응증) · TP 42 (RepoDB 승인) · 문헌량을 맞춰 짝지음	개발 · 보정 적합
봉인 홀드아웃	TN 387 (ClinicalTrials.gov 효능 실패 중단 시험에서 새로 수확 · 약물 단위 해시로 개발/봉인 분할 · 교집합 0) · TP 387 (RepoDB 승인) · 두 번 열었다 — 첫 개봉은 개발 단계 모델, 두 번째 개봉이 제출 모델(\$4.1)	주 평가 · 결과를 보기 전에 동결
전향 봉인	진행 중 임상 60건(1차 완료 후 11~13개월 · 결과 미게시) · 무작위 음성대조 20쌍 · 개발 단계 모델	결과가 나오면 대조
생성 실험	질환 12개 → 후보 340건 · 확장 질환명 37개(동의어 포함) → 후보 1,074건 · 둘 다 개발 단계 모델	생성기 관찰 (\$4.5)

누출 차단 — 라벨이 된 시험과, 색인으로 찾을 수 있는 그 결과 논문은 근거에서 뺀다(본선 실행 294 건). 색인이 없는 211건은 못 막으므로 «**볼 수 있는 누출만 제거했다**» 가 정확한 문장이다. 차단이 새는 지 첫 개봉에서 실측했다 — 색인된 80건 중 6건(7.5%)이 라벨 출처 논문을 읽고 있었다. 6건 모두 기각이었고 그중 5건은 그 논문이 결정적이었다. 주지표 판정(미달)은 바뀌지 않았다(\$5).

정답표 감사 — 개발 벤치마크의 TN 후보 49건의 ClinicalTrials.gov 원문을 전부 읽었다. **효능 실패가 아닌 것이 18/49 = 37%** 였다(안전성 · 독성 11 · 모집 · 사업상 5 · 다른 연구 근거 2). 분류 규칙을 코드로 고정한 값이고, 즉석 계산으로는 43%가 나왔다. warfarin 한 건이 문제를 보여 준다 — 시험은 치료군 사망 초과로 멈췄는데 시스템은 효능 근거로 기각했고, 그 근거 문장은 안전성 이야기였으며 내용은 «차이가 없다» 였다. **맞은 것이 아니라 우연히 같은 칸에 떨어졌다.**

(개발 단계 모델)	기각 정밀도	기각 재현율
전체 TN 42 — 주 수치	7/7 = 100% [65–100]	17% [8–31]
효능 실패만 27 — 사후 민감도 분석	5/5 = 100% [57–100]	19% [8–37]

방향은 살아남고 하한만 내려간다. 우리가 쟀 것은 «효능 실패를 걸렀는가» 가 아니라 «어떤 이유로든 중단된 시험을 걸렀는가» 에 가깝다. **정답표는 고치지 않는다** — 결과를 보고 정답을 고치면 측정이 아니라 조작이다. 실패 모드별 라벨링은 다음 명세에서 사전에 한다. 봉인 홀드아웃의 TN 은 이 감사를 하지 않았다 — 등록 미달을 효능 실패로 잘못 분류한 것만 켜다(봉인 짝의 0.5%).

«모름» 부분집합 — B0 가 «모름» 이라 답한 문항. 라벨이 아니라 **모델의 출력만으로** 고르므로 «모델 기억 밖» 을 재는 데 쓴다. 결과를 본 뒤 정했으므로 **사후**라고 적는다.

3.3 사후편향을 빼는 세 단계

단계	방법	남는 사후편향	결과
① 후향 홀드아웃	결과를 보기 전에 동결한 774쌍 — 제출 모델로는 한 번 돌렸다(같은 홀드아웃의 두 번째 개봉)	있다 — 결말이 모델 학습 자료에 있을 수 있고, 첫 개봉 결과를 우리가 이미 봤다	§4.1
② 시점 차단	시험 종료 1년 전까지 발행된 문헌만 쓴다	일부 — 모델이 결말을 기억할 수 있다	§4.4
③ 전향 봉인	결과가 아직 없는 임상을 예측하고 봉인한다	없다	§4.8

②의 한계를 줄이려고, 판정은 검색된 근거 사슬로만 계산하고 차단 시점 이후에 발행된 PMID 는 근거로 인정하지 않는다.

3.4 사전명세 — 결과를 보기 전에 기준을 적는다

사전 기준이 있는 실험마다 **주지표 · 성공 기준 · 예측 · 반증 조건**을 먼저 적고 sha256 으로 봉인한 뒤 돌렸다. 봉인한 명세 31개에서 나온 기준을 하나도 빠지 않고 대장(사전기준_대장.csv)에 적었고, 대장과 문서의 집계가 같은지는 코드가 본다. 결과는 §4.3.

«먼저 적었다» 는 증거의 강도는 셋이다 — 섞어 적지 않는다.

강도	무엇이 증명하나	해당
강	봉인 해시를 제3자 타임스탬프(OpenTimestamps · 비트코인 블록)로 등록	라우터 분기 · 등록부 실험(등록 당시 미실행) · 전향 봉인 예측 80건(예측도 등록도 임상 결과가 나오기 전)
중	명세와 결과의 git 기록 — 커밋 시각은 우리 컴퓨터가 만든 것이다. 작업 저장소는 비공개이고, 공개 저장소(제출 시점 사본)에 명세 · 결과 파일의 커밋 기록을 뽑아 싣는다(커밋기록_요약.txt)	대부분의 명세
약	로컬 봉인 파일 — 봉인 파일 뒤에 실행했지만 커밋은 실행 뒤였다(저장소 잠금 사고로 커밋이 엇새 밀렸다)	본선 홀드아웃 · 시점 차단 명세

4. 결과

4.1 본선 홀드아웃 774쌍 — 파이프라인과 모델 단독

수는 `py -m bioreroute.bench.perfcard` 가 결과 파일(홀드아웃_본선모델.json)에서 낸다 — 손으로 옮기지 않았다. 발표의 성능 장도 같은 함수를 부른다. 모델 `gpt-5.6-terra` · seed 42 · 결과를 보기 전에 봉인한 명세대로 **한 번** 돌렸다 — 같은 홀드아웃의 **두 번째 개봉**이다(첫 개봉은 개발 단계 모델).

평가 기준 — 이 순서로 본다 (제안서 §4)

1. **기각이 맞았나** — 기각 정밀도(기각한 것 중 실제로 실패한 약)
2. **맞는 것을 버렸나** — 성공한 약을 기각한 비율
3. **모르면 모른다고 하나** — 보류 비율 · Brier 를 **넌 모형(늘 기저울)**과 **나란히**. ECE 는 쓰지 않는다 — 균형 집합에서 넌 모형의 ECE 가 0 이다
4. **모델 기억이 아닌가** — 모델 단독(B0)을 같은 쌍에 나란히 적고, 모델이 문헌 없이 «모름» 이라 한 문항에서 따로 쟀다. AUROC 는 보조다(«보류» 를 0.5 로 뭉갬다)

지표	파이프라인 B5 · 전체 774쌍	모델 단독 B0 · 전체 774쌍	B5 · 모델이 «모름» 이라 한 445쌍 (사후)
기각 정밀도 (B0 는 «실패»)	99/105 = 94.3% [88.1–97.4]	122/126 = 96.8% [92.1–98.8]	38/41 = 92.7% [80.6–97.5]
기각 재현율 (TN 중)	99/387 = 25.6% [21.5–30.2]	122/387 = 31.5% [27.1–36.3]	38/199 = 19.1% [14.2–25.1]
성공한 약을 버림 (TP 중)	6/387 = 1.6% [0.7–3.3]	4/387 = 1.0% [0.4–2.6]	3/246 = 1.2% [0.4–3.5]
«유망» 정밀도 (B0 는 «성공»)	126/167 = 75.4% [68.4–81.4]	137/203 = 67.5% [60.8–73.6]	40/48 = 83.3% [70.4–91.3]
보류 (B0 는 «모름»)	473/774 = 61.1% [57.6–64.5]	445/774 = 57.5% [54.0–60.9]	343/445 = 77.1% [73.0–80.7]
조건부	29/774	—	13/445
AUROC [95% CI]	0.712 [0.676–0.748]	0.698 [0.661–0.735]	0.670 [0.621–0.720] · B0 는 정의상 0.500
Brier (넌 모형)	0.219 (0.250)	0.218 (0.250)	0.221 (0.247)

전체 표본에서는 모델 기억이 더 잘 거른다. 모델 단독은 126건을 «실패» 로 버렸고 파이프라인은 105건을 기각했다. TN 에서 짝지어 보면 모델 단독만 버린 쌍 70 · 파이프라인만 버린 쌍 47 (McNemar $p = 0.042$ · **사후**). AUROC 와 Brier 도 구별되지 않는다 — 이 표본에서 모델 단독에 대한 우위를 주장하지 않는다.

파이프라인의 뒤편은 모델이 모르는 곳이다. 모델 단독이 «모름» 이라 답한 445쌍에서 모델 단독은 정의 상 아무것도 거르지 않는다(0/199). 여기서 파이프라인은 41건을 기각했고 38건이 맞았다 — 이 부분 집합의 실패 비율은 $199/445 = 44.7\%$ 라, 무작위로 기각하면 정밀도가 그 근처다. 이 부분집합은 결과를 본 뒤 정했다(사후) — 다만 라벨이 아니라 **모델의 출력만으로** 고른다.

모델 4개 — «모름» 문항의 파이프라인 AUROC: mini 0.615 · terra 0.670 · sol 0.692 · luna 0.642 · 95% CI 가 모두 겹친다(공통 [0.641, 0.667] · 사후). **이 표본으로는 모델 간 차이를 가르지 못한다.**

기각 문턱은 모델에 달렸다 — 표적 재시험(사전 지정 · 새 seed 셋): sol 만 기각 33 · luna 만 기각 7 · McNemar $p = 4.2e-05$. 두 모델이 처음 같았던 27쌍에 한정한 결과다.

seed 흔들림 — 같은 모델·다른 seed 판정 불일치 6.0% · 다른 모델 9.1% → 모델을 바꾸면 seed 를 바꿀 때보다 판정이 더 흔들린다 (추출 복제 · 사전 지정).

⚠ **한계** — ① TP(RepoDB 승인)는 모델이 학습 중 봤을 가능성이 크다 — 전체 표본의 모델 단독은 **암기 천장**이다 ② «모름» 부분집합은 **사후**다 ③ 라벨로 걸러 낸 «누출 제외» 부분집합은 모델 단독을 기계적으로 낮춘다(고확신 오답 37건이 남는다) — 비교에 쓰지 않는다.

4.2 보정 — 확률이 정직한가

Platt 보정(2모수 로지스틱[11])을 **개발 벤치마크(층 A)의 terra 점수로 적합해** 홀드아웃에 적용했다(층 A 와 겹치는 4쌍을 빼 770쌍). 보정은 단조변환이라 판정 · AUROC · 기각 정밀도는 바뀌지 않는다. 보정 모델은 그 모델의 점수에 맞춰야 하므로 개발 단계 모델로 맞춰던 사상을 쓰지 않고 terra 로 다시 맞췄다(봉인 명세가 «재적합은 개발집합에서만» 을 허용한다).

Brier (낮을수록 좋다 · 770쌍)	원점수	Platt (층 A · terra 적합)
파이프라인 B5	0.220	0.212
모델 단독 B0	0.219	0.222
널 모형(늘 0.5)	0.250	—

짜지은 부트스트랩(2,000회) 구간으로 읽으면 —

- 보정은 파이프라인의 Brier 를 조금 낮춘다: -0.0077 [-0.0140, -0.0018]
- **파이프라인과 모델 단독은 구별되지 않는다** — 원점수끼리 +0.0010 [-0.0137, +0.0157] · 둘 다 보정해도 -0.0098 [-0.0251, +0.0046]
- 개발 단계 모델로 맞춘 사상과도 구별되지 않는다: -0.0008 [-0.0020, +0.0004] — 모델에 맞춰 다시 맞추는 것이 원칙이지만 결과는 거의 같았다
- 모델 단독의 보정 효과는 **적합에 쓴 개발 실행에 따라 방향이 바뀐다** — 계산 전에 정해 둔 09-12 실행으로 맞추면 +0.0031 [+0.0013](#), [+0.0050](#), 같은 84쌍을 09-20 에 다시 돌린 실행으로 맞추면 -0.0029 [-0.0047](#), [-0.0013](#) 이다(사후 민감도). 모델 단독 점수는 다섯 값뿐이고 같은 84쌍을 다시 돌리면 답이 바뀌어(두 실행 사이 15쌍) 84쌍으로 맞춘 사상이 안정하지 않다. 파이프라인은 두 적합에서 0.212 로 같았고, 모델 단독과 구별되지 않는다는 결론도 같았다

수는 전부 `calibrate` 가 결과 파일에서 낸다 — 구간까지(재현 명령은 §9). **화면이 보여 주는 %는 보정 전 값이다** — 실시간 경로에는 보정을 붙이지 않았다. (전문: 보정결과_terra.md)

4.3 사전 기준 판정 — 42개를 하나도 빠지 않고

사전 기준 42개 — 통과 20 · 미달 14 · 판정 불가 8. 기준이 없는 절차 명세 3개와, 전제가 먼저 반증돼 실행하지 않은 명세 1개는 세지 않았다.

판정	기준 (대장 사전기준_대장.csv 의 행을 줄여 적었다)
통과 20	생성 실험 — 효능 실패 비율의 신뢰구간 하한이 무작위보다 높다 · 라우터 병원체 분기 8/8 · 0/8 · 그래프 검색 두 방식 · 역발상(FAERS · SIDER) · 보정 두 기준(ECE 기준 — 뒤에 주장을 거뒀다) · 회의주의자가 홀드아웃에서 반박 근거를 늘린다(두 기준) · 라우터 그래프(사례 3건) · 병명 입구 두 기준 · 모델 교체 판정 불일치 4.1% · 재시험 판정 일치(개발 6쌍) · 확률 변동폭 중앙값(개발 · 본선 재적용) · 모델 교체 시 검증 경로 불일치(luna · sol 각 1/98) · 네 모델 신뢰구간 겹침(약한 기준) · sol 의 초과 기각이 새 seed 에서 되풀이(33 대 7)
미달 14	홀드아웃 풀의 무작위 비율 38.8%(신뢰구간이 29%를 포함해야) · 시점 차단 비율(개발 모델 · 본선 모델 0.939 — 둘 다 ≤ 0.50 이어야) · 등록부 개입(판정이 갈린 쌍 0) · 그래프 검색 한 방식 · 역발상 순위를 성능으로 팔 수 있는가(보조 기준) · 용도 특허 신호 세 기준 · 회의주의자가 홀드아웃에서 근거 기반 기각을 늘린다(승인약 오기각 +5) · 병명 입구 두 기준(F0 통과율 · 150초) · 본선 재시험 판정 완전일치 72/84 · 추출 복제(모델 차이가 seed 흔들림보다 크다 — 예측은 «구별 안 됨»)
판정 불가 8	깎때기 실험($p = 0.077$ · 검정력 60%) · 회의주의자 28쌍 두 기준(검정력 2.5%) · 용도 특허 대조(검정력 31.3%) · 종 관문 16쌍 · 도킹 데모 · 전문 읽기 · 네 번째 모델 확인 검정($b \cdot 6 \cdot c \cdot 8 \cdot p = 0.79$)

셈법에 판단이 들어간다. 요약 문서들이 «미달» 로 적어 온 판정 불가를 미달로 세면 17, 재적용을 빼면 13 이 된다. 그래서 한 수만 고르지 않고 대장 전체를 공개한다. **결과를 본 뒤 기준을 낮춘 기록은 없다** — 문턱을 고친 한 번(시점 차단 비율의 기준값)은 더 엄격해지는 쪽이었다. **봉인 뒤 본문을 고친 명세가 둘 있다** — 전문 읽기 명세는 봉인 직후 구성 이름만 고쳤고(결과 전), 모델 교체 명세는 봉인 다음 날 덧붙인 문단 때문에 1차 봉인 본문을 되살릴 수 없다. 둘 다 다시 봉인하며 두 해시를 남겼다.

4.4 시간 구조 — 반증 근거는 늦게 온다

같은 774쌍을 시험 종료 1년 전까지의 문헌만 보게 막고 다시 돌렸다(사전 지정).

TN 387	전 기간	1년 전 차단
총 기각	99/387 = 25.6%	93/387 = 24.0%
↳ F0 기각 (차단 시점 이전 문헌에서 약물이 안 잡힌다 · 전 기간의 33 에는 조회 한도 초과가 잘못 들어간 1건 포함 · §2.5)	33	69
↳ 근거 기반 기각	66/387 = 17.1%	24/387 = 6.2%

사전 기준은 미달이다 — «차단 후 ÷ 전 기간 ≤ 0.50 » 이어야 했는데 0.939 다. 분해하면 이유가 보인다 — 근거가 «있어서» 한 기각이, 근거가 «없어서» 한 기각으로 대체됐다. 근거 기반 기각만 세면 17.1% → 6.2% 로 무너진다. 시간 구조는 있었고, 총량으로 세는 지표가 그것을 감췄다. 다만 사전에 «기각 재현율» 이라고만 적었으므로 **미달은 미달로 보고하고**, 분해는 결과를 본 뒤의 분석으로 적는다.

부수 효과 — 시점 차단은 누출 차단을 겸한다. 라벨이 된 시험의 결과 논문은 종료 **이후**에 나오므로, 같은 홀드아웃의 첫 개봉(개발 단계 모델)에서 1년 차단 실행의 누출은 0건이었다.

4.5 생성 — 무엇이 나오는가

사전명세 실험 — 질환 12개 × 프롬프트 2종 × 요청 20개 → 후보 340건(개발 단계 모델 gpt-5.4-mini). «확실한 것만» (strict)과 «확신 없어도 좋다»(loose)를 **둘 다** 돌렸다 — 프롬프트 한 줄이 결론을 정하지 않게 하려고.

	strict	loose
요청 대비 생성 충족	119/240 = 49.6%	221/240 = 92.1%
이미 그 병의 승인약 (프롬프트가 명시적으로 금지)	28/119 = 23.5%	52/221 = 23.5%
이미 효능 실패로 중단된 약	3/119 = 2.5%	6/221 = 2.7%

사전 기준(효능 실패 비율의 95% 신뢰구간 하한 > 무작위 기준선 0.36%)은 **통과했다** — 우연의 약 7배다. 그런데 **우리 예측(5-15%)은 빗나갔다**. 크게 나온 것은 다른 곳이었다 — **넛에 하나가 이미 그 병의 표준치료**였고, 질환별로 방향이 읽힌다(고콜레스테롤혈증 13/20 = 65% · 류마티스 관절염 10/21 = 48% · 궤양성 대장염 14/35 = 40% · 유방암 2/32 = 6% · 조현병 0/35 = 0%). 표준치료가 굳어 있을수록 그것을 재창출 후보로 내민다. 신중하라고 시키면 **개수는 절반으로 줄었지만 승인약 재탕 비율은 같았다** — 적어도 이 지표에서 생성기의 자제는 수량 자제였다(효능 실패 비교는 검정력 3%라 모른다).

확장 실행 — 질환명 37개(효능 실패 · 승인이 각 3건 이상인 것 전부 · 동의어가 섞여 있다) · 같은 프롬프트 2종 → 후보 1,074건(개발 단계 모델).

생성기가 낸 것	비율
이미 그 병의 승인약	17% [15–19]
이미 효능 실패로 중단	2% [2–3] (25건)
사유 불명으로 중단	10%
우리 자료에 없음 (신규 후보라는 뜻이 아니다)	71%

가장 강한 관찰 — 생성기는 실패를 말하지 않았다. 사전명세 실험에서 효능 실패로 잡힌 9건의 근거 문장을 전부 읽었다. 실패 · 무효 · 중단을 언급한 것은 **0건**이다(9건이라 95% 신뢰구간 상한은 30% · 사후 감사에서 9건 중 2건은 등록 미달이 효능 실패로 잘못 분류된 것이었다).

후보	생성기가 적지 않은 것
pioglitazone / 알츠하이머병	TOMMORROW · n=3,494 · «Lack of efficacy»
azithromycin / 천식	AZ-SWED · n=840 · NHLBI 가 무익(futility)으로 중단
losartan / COVID-19	NCT04606563 · n=341 · 자료감시위원회 무익 판정
camostat / COVID-19	NCT04625114 · n=108 · 중간분석 무효

지어낸 문장은 없었다 — 전부 사실이고 **한쪽만 담았다**. 9건 중 6건은 스스로 «임상 근거 있음» 이라 표시했는데, 그 임상 근거가 바로 실패한 그 시험이다. 340건 전체에서도 근거에 부정적 표현이 들어간 것은 $23/340 = 6.8\%$ 뿐이다. 반증 깔때기가 필요한 이유다. 실패를 먼저 말하라고 시키는 프롬프트는 시험하지 않았다.

4.6 인용 검증 — «생성된 정보가 실제 데이터와 일치하는가»

본선 홀드아웃 실험의 인용 **전부**를 켜다(LLM 0회 · 판정할 때 기록된 대조 결과를 다시 읽었다 · 본선보조분석_0926.md).

	실측 [95% CI]	분모
충실도 — 인용 문장이 초록 원문에 실재	2128/2129 = 99.95% [99.73–99.99]	검사까지 간 인용
관련성 — LLM 이 낸 인용 중 쓸 수 있던 것	2129/6657 = 32.0% [30.9–33.1]	LLM 이 낸 인용 전부
초록에 없는 문장 (지어낸)	1건	—

분모를 둘로 나눈 것이 요점이다. 검사 전에 빠진 4,528건(무관 3,927 · 초록 없음 306 · 라벨 출처 192 · 기타 92 · 철회 11)을 «불충실» 로 세면 틀리고, 분모가 줄었다는 사실을 감추면 충실도가 부풀려진다.

그리고 문자열 대조로는 안 걸리는 층이 더 크다.

층	걸림 / 기회	비율
연구 유형 충돌 — LLM 이 말한 유형이 PubMed 와 다르다	844/6056	13.9%
결과를 진술하지 않는 문장 («측정 방법» · «환자 배정»)	374/2128	17.6%
그 약을 지목하지 않는 간접 근거	270/2128	12.7%
같은 시험의 중복	40/261	15.3%

지어낸 것은 6,657건 중 1건이고, 관계가 틀린 것은 열에 한두 건이다. 이 시스템이 존재하는 이유가 그 층이다. 이 수치는 RAGAS 가 아니고(LLM 심판을 쓰지 않는다), 원문 대조 자체는 우리 발명도 아니다 — CiteCheck 가 원문 일치에 의미 유사도까지 더해 더 넓게 본다[9]. 사전 문턱이 없는 서술 결과다.

4.7 판정은 얼마나 단단한가

물음	실측	읽기
근거 하나만 빼면 뒤 집히나 — 판정 취약성[12]	기각 105건 중 39건이 취약도 1 · TN 기각 38/99 · TP 기각 1/6	판정만 보지 말고 근거 목록을 같이 봐야 한다
같은 모델 · 같은 seed 로 8일 뒤 다시	84쌍 중 판정 완전일치 72/84 (사전 기준 미달) · 확률 변동폭 중앙값 0.0%p(통과) · 평균 3.8%p · 최대 49%p	대부분 그대로지만 경계 사례가 움직인다
seed 만 바꿀 때와 모델을 바꿀 때	판정 불일치 6.0% 대 9.1% · 차 +3.1%p [+2.1, +4.1] (사전 지정 · 우리 예측은 «구별 안 됨» 이었고 빗나갔다)	모델을 바꾸는 효과가 더 크다
두 모델이 갈린 쌍을 새 seed 로	sol 만 기각 33 · luna 만 기각 7 · $p = 4.2e-05$ (사전 지정)	기각 문턱은 모델의 성질이다
가장 강하게 기각한 100개의 정밀도	모델 단독 0.972 · 파이프라인 0.950	강한 모델은 외워서 맞히는 폭이 넓다 (약한 개발 모델에서는 0.686 대 0.890 으로 반대였다)

(전문: [본선보조분석_0926.md](#) · [재현성결과_0920.md](#) · [홀드아웃_본선모델_결과.md](#))

4.8 전향 봉인 예측 — 결과를 모르는 채로 봉인했다

진행 중 임상 60건(1차 완료 후 11~13개월 · 결과 미게시)과 무작위 음성대조 20쌍을 예측하고(개발 단계 모델 · 구성 B5), 그 해시를 제3자 타임스탬프로 등록했다. **결과가 나오기 전에 봉인했으므로 우리가 결과를 보고 고칠 수 없는 유일한 숫자다.** 결과는 2027년까지 나온다.

	유망	조건부	보류	기각
진행 중 60건	22	0	27	11
무작위 음성대조 20쌍	0	0	17	3

결과를 안 기다려도 나온 것 하나 — 무작위 쌍에 «유망» 을 준 것이 하나도 없다(진행 중 22/60 = 37% 대 음성대조 0/20 · $p < 0.001$). 문헌량을 맞춰도 68% 대 0%($n = 31$ 대 6 · $p = 0.003$)로 남는다. 다만 맞춘 뒤 대조군이 6건뿐이라 0% 가 아니라 «39% 이하» 로 읽어야 한다.

그리고 제안서의 예측은 빗나갔다. 제안서는 음성대조를 «낮은 신뢰도로 기각» 할 것이라 썼는데, 시스템은 기각하지 않고 기권했다(17/20 = 85% 보류). 근거가 없으면 판단하지 않는 것이 설계이고, 틀린 것은 제안서의 문장이다.

4.9 유의한 값을 하나 버렸다 — 교란

같은 홀드아웃의 첫 개봉(774쌍 · 개발 단계 모델)에서, 모델 단독이 «모름» 이라 한 문항만 모아 파이프라인의 정확도를 재니 다수클래스보다 유의하게 높았다. 사전에 지정해 둔 **문헌량 균형 부분집합**에서 다시 재니 사라졌다.

	미지 영역 정확도	다수클래스	p
전수 (TN-TP 짝 387)	75% (101/135)	59%	< 0.001
균형 짝 56 (사전 지정)	65% (15/23)	61%	1.000
개발 벤치마크 (짝 42 · 문헌량이 맞춰진 원본)	65% (13/20)	57%	0.509

문헌량 교란이었다(\$8 한계 3). 균형을 맞추면 65%로 내려가 다수클래스와 구별되지 않고, 그 65%가 원본 벤치마크와 같다. 여기서 멈췄으면 «미지 영역에서 유의하게 우수하다» 고 보고했을 것이다. **사전 명세가 막은 것은 실수가 아니라 자기기만이다.**

4.10 «모른다» 와 «차이 없다» 는 다르다 — 갈때기 실험

생성된 후보를 갈때기가 실제로 거르는지 봉인하고 잤다(개발 단계 모델).

TN(효능 실패) 근거 기반 기각 6/14 = 42.9% [21.4-67.4]
 TP(승인) 근거 기반 기각 1/14 = 7.1% [1.3-31.5]
 Fisher $p = 0.077$ · 검정력 60% · 필요 표본 22쌍(실행 전에 계산) · 실제 14쌍

방향은 6배 차이인데 유의하지 않다. 필요 표본을 **실행 전에** 계산해 두었고, 14쌍밖에 못 모았다. 이 실험의 결론은 «**효과 없음**» 이 아니라 «**측정 불가**» 다 — 판정 불가로 썼고, «차이 없다» 로 쓰지 않았다.

4.11 발굴 보조 — 역발상 · 그래프 · 특허

	무엇을 했나	결과
역발상 발굴 (FAERS 부작용 신호)	상위 후보가 무작위보다 문헌이 있는 후보를 더 내는가	F0 통과 82.3% 대 무작위 64.0% · Fisher p = 0.006 — 통과
역발상 발굴 (SIDER)	같은 기준 · 순위가 부작용 수를 재고 있는가(보조)	기준 통과(경계) · 보조 기준 미달 → 순위를 성능으로 내세우지 않는다
그래프 검색 (DRKG)	세 방식이 차수 대조군을 이기는가	둘 통과 · 하나 미달
특허 (SureChEMBL 로컬 색인)	관련 특허 검색 · 용도 특허 신호	검색까지 — 신호는 기준 미달(공동청구 72.7% · 기준 $\leq 60\%$)이라 판정에 쓰지 않는다

역발상은 «**정보가 있는 후보를 무작위보다 많이 낸다**» 까지만 했다. 그 후보가 맞는지는 재지 않았다.

5. 우리 도구를 우리가 반증한 기록 — 결함 369건

측정 · 문서 · 절차에서 스스로 찾은 결함 369건을 전부 공개한다(Bio-ReRoute_발견정리.md · 건마다 코드 위치와 결과). 유형 여덟으로 묶으면 반복이 보인다.

유형	건수	대표 사례
검증 환경 ≠ 실행 환경	34	모의로만 줄곧 → 첫 실패율이 0건 · 안 써 본 의존성이 다섯 달 전에 죽어 있었다 · 모의가 실제 출력 형식보다 좁아 시험이 초록인 채 실패를 감쌌다
캐시는 최적화가 아니라 자료원	16	일시 장애 380건이 캐시에 박혀 누출 차단이 88%에서 안 걸렸다 · 읽기 실패를 «빈 캐시» 로 승격시켜 33MB 를 스스로 지웠다
규칙·검정을 잘못 골랐다	10	상수 기준선에 Fisher · 한 후보에 무게 체계가 둘 → 유망 90%
같은 실수가 파일을 옮겨 재발	25	숫자 표기 드리프트 세 번 · 일괄 치환 사고 일곱 번 · 새 파일이 <code>cache.load()</code> 를 안 불렀다 · 틀린 값이 발표자료로 베껴졌다
안내문은 방어가 아니다	46	검토지에 답을 넣고 “보지 마라” · 검증절차를 만든 날 밤에 그 절차를 건너뛴
재는 것 ≠ 잰다고 말하는 것	143	정답표의 37%가 다른 실패 모드 · 우리 작업 기간을 실제의 3배로 적었다 — 99곳 · 「기각 재현율」의 분자에 오답이 섞인 채 7주
만든 것을 눈으로 안 봤다	49	표가 깨지고 마크다운이 노출됐다 — 5.9 GB 를 받아 색인하고도 그 파일을 안 읽었다 · 화면 클릭 한 번이 30초인 걸 아무도 안 잰다
고친 자리의 이웃을 안 본다	46	질의를 고치니 그 문구로 분기하던 곳이 죽고, 라벨을 늘리니 쓰는 쪽이 몰랐다 — 허브 편향을 고친 것은 대조군보다 나빴다
합	369	대장(Bio-ReRoute_발견정리.md)의 행 수와 같다 — 회귀 시험 65번이 지킨다

(이 표는 발표 «우리 도구를 우리가 반증한 기록» 장의 막대와 같은 목록에서 나온다 — `py -m bioreroute.bench.defecttypes`)

여덟 유형이 같은 결말이다 — «조심하자» 로는 안 막혔고, 코드가 막으니 막혔다. 그래서 규약을 하나씩 구조로 바꿨다.

되풀이된 실수	규약이었던 것	구조로 바꾼 것
문서마다 수치가 갈라진다	«고칠 때 다 찾아 고쳐라»	문서 감사기가 결함 수 · 시험 수 · 판 번호 · 사전 기준 집계를 문서 전부에서 대조하고, 정본과 다르면 고치는 명령을 찍는다
손으로 옮긴 수가 틀린다	«코드에서 복사해라»	이 보고서의 §4.1 · 결함 유형 표 · 발표 성능 장을 결과 파일에서 직접 생성 한다
조회 실패를 0건으로 센다	«실패를 조심해라»	실패한 쌍은 분모에서 빼고, 전부 실패하면 판단을 거부한다
시험이 실제 자료를 덮어쓴다	«시험은 임시 폴더에서»	시험 중 저장소 쓰기를 막는 감시기 — 쓰면 실패로 올린다
저장이 끊기면 반쪽 파일이 남는다	«조심해서 저장»	임시 파일에 쓰고 원자적으로 바꾼다
배포했다고 믿는다	«올렸는지 확인해라»	배포본을 내용 해시로 대조하는 확인 도구

가장 위험했던 것은 **우리에게 유리한 고장**이었다. 한 도구가 조회 실패(네트워크 403)를 0건으로 합산해 «반증 근거의 부재는 구조적이다» 라는 결론을 출력했다 — 논지를 지지하는 방향이었고, **숫자가 너무 좋아서** 의심한 것이 유일한 방어였다. 그것은 방어가 아니다. 두 번째로 아팠던 것은 캐시에 박힌 일시 장애가 누출 차단을 무력화한 것이다 — 실측하니 색인된 80건 중 6건이 라벨 출처 논문을 읽고 있었다. 주지표 판정은 바뀌지 않았지만 **그 여섯은 예측이 아니라 답안지 읽기**였고(6건 모두 기각 · 5건은 그 논문이 결정적), 이름과 가중치까지 적었다.

고치지 않기로 한 결함도 남긴다. 메타분석 넷이 같은 시험들을 재탕했는데 독립 근거로 세어져 플루복사민 / 코로나19 가 «유망 97%» 가 된다(개발 단계 데모) — 메타분석에는 시험 번호가 없어 중복 제거가 걸리지 않는다. 가중 규칙을 바꾸면 지금까지 켜 모든 수치가 다른 시스템의 수치가 되므로 고치지 않고, 근거 카드에서 그 이유가 그대로 보이게 둔다. 감사 추적이 본체라는 주장의 가장 좋은 증명은 **자기 오류를 보이는 것**이다.

6. 반증 조건 — 이 관찰이 나오면 우리 논지가 틀렸다

중심 명제: «값싼 반증 관문을 앞에 두면, 그럴듯하지만 틀린 후보를 더 정확하게 거르고 더 정직한 확률을 낸다.»

#	이 관찰이 나오면 틀렸다	본선 결과
F1	관문을 전부 꺼도(모델 단독) 특이도가 같거나 낮다	전체 774쌍에서 실현 — 모델 단독이 더 많이, 더 정확하게 거른다(기각 재현율 31.5% 대 25.6% · McNemar $p = 0.042$ · 사후). 모델이 «모름» 이라 답한 445쌍에서는 아니다 (사후) — 정의상 모델 단독은 거르지 않고, 파이프라인은 TN 199 중 38 을 걸렸다(기각 41건 중 38건 적중 · 이 부분집합의 실패 비율 44.7%)
F2	보정이 관문으로 좋아지지 않는다	실현 — Brier 가 모델 단독과 구별되지 않는다(원점수 · 보정 후 모두). 나빠진 것도 아니다
F3	반증 근거가 애초에 없다	부분 실현 — 종료 시험 전체에서는 2.3%. 제안된 후보로 좁히면 79%(사후)
F4	생성기가 이미 실패를 알고 피한다	반증됨 — 효능 실패 후보 9건 중 실패를 언급한 것 0건(개발 단계 모델 · 9건 중 2건은 사후 감사에서 등록 미달로 밝혀졌다)
F5	걸러낸 후보가 사후에 유효로 밝혀진다	부분 실현 — 기각 105건 중 6건이 승인약(5.7%) · 그중 근거 하나로 뒤집히는 것은 1건이고, 2건은 옛 약 이름이 PubMed 에 없어 F0 로 기각됐다

읽기 — 다섯 중 둘이 실현, 둘이 부분 실현이다. 논지는 좁혀진다 — **모델이 이미 아는 후보에서는 관문이 모델 기억을 이기지 못하고, 모델이 모르는 후보에서 값을 한다**(사후 부분집합에서 본 것이다 · 일반 질의응답에서 이미 보고된 모양이다[23]). 생성형 모델이 커질수록 «아는 영역» 은 넓어지므로, 이 시스템의 쓸모는 **기억 밖의 후보를 근거와 함께 거르는 것과 왜 그렇게 판정했는지 남기는 것**으로 모인다.

7. 선행연구 — 무엇이 우리 몫인가

열 번 찾았고, 찾을 때마다 주장이 줄었다.

우리가 주장하려던 것	선행연구	판단
«반증의 병목»이라는 문제 정의	Maziarz & Stencel 2022 — 사례 약물도 HCQ[4]	철회 — 우리는 그 처방을 절차로 만들었다
도킹이 대개 맞지 않는다	감염을 줄인 약 77개 중 76개가 바이러스 단백질에 안 붙는다[5]	철회 — 우리 몫은 후보별 자동 판단과 기록
생성기-회의주의자 토론 구조	RareAgent[7]	철회
역사적 실패를 음성으로 쓰는 벤치마크	실패를 단계별로 등급화(hard · medium negative)한 선행 벤치마크	철회 — 그쪽이 더 정교하다
AUROC 를 그대로 믿지 않는다 · 코드 공개	Guney 2017 — 약물을 분리하면 AUC 84.1% → 65.6%[8]	축소
인용을 원문 문자열로 대조	CiteCheck[9] · CiteGuard[18]	철회 — CiteCheck 가 더 넓다
활성부위 pLDDT 를 도킹 기준으로	결합 부위 pLDDT 가 70 이상인데 도킹 성능이 나쁜 사례[10]	필요조건으로만 쓴다
저자가 적은 한계로 근거 무게를 내린다(전문 읽기 F)	GRADE — 연구의 한계가 심각할수록 근거 수준을 내린다[20]	철회 — 우리 것은 GRADE 의 조잡한 자동화판이다
사전등록 · 봉인 방법론	LLM 평가 분야의 사전등록(OSF 등)[21][22]	도메인 이전이지 발명이 아니다 — 그쪽은 제3자 저장소에 등록했다
모델이 모르는 후보에서 파이프라인이 값을 한다 (§4.1 · 사후)	덜 유명한 개체에서는 검색으로 보강한 모델이 훨씬 큰 모델을 이기고, 유명한 개체에서는 보강 없는 모델도 경쟁력이 있다[23]	도메인 사례이지 새 발견이 아니다 — 모델이 «모름» 일 때만 검색하는 구성도 그쪽 제안이다
미리 정한 기준으로 재고 미달을 공개한 것	찾지 못했다	남는다 — «못 찾았다» 는 «없다» 가 아니다
스스로 찾은 결합 369건 공개	찾지 못했다	남는다
후보마다 검증 경로를 정하고 안 돌린 이유를 판정 기록에 남기는 구현	구성 요소는 있다[5][7]	구현과 그 실측(라우터 8/8 · 0/8 · 도킹 9/9 불가)이 우리 몫이다

Guney 의 결과는 우리 AUROC 를 읽는 데도 쓴다 — 약물을 분리해 평가하면 AUC 가 65.6%로 내려간다[8]. 과제와 자료가 달라 직접 비교할 수는 없지만, «0.7 대는 낮다» 는 인상은 분할 방식이 만든 기대치일 수 있다.

8. 한계

1. **모델 단독에 대한 우위가 없다.** 전체 표본에서 모델 단독이 더 거르고(\$4.1), 보정도 구별되지 않는다(\$4.2). 파이프라인의 뒤편 모델이 모르는 후보(사후)와 근거 추적이다
2. **정답표 양쪽이 깨끗하지 않다.** TP 는 RepoDB — 모델이 학습 중 봤을 가능성이 크다(암기 천장). 개발 벤치마크 TN 49건 중 37%는 효능 실패가 아니었고, 봉인 홀드아웃 TN 은 실패 모드별로 감사하지 않았다(\$3.2). 실패 모드별 라벨링은 다음 명세에서 사전에 한다
3. **문헌량 교란.** 홀드아웃 TN 은 최근 종료된 시험이라 문헌이 적고(중앙값 5건) TP 는 많다(28건) — 치우침 $+0.471$ 은 허용치(± 0.15)의 3배다. 다음 홀드아웃은 TN · TP 를 같은 모집단에서 뽑아야 한다
4. **검정력이 모자란 결과가 많다.** 그것을 «차이 없다» 가 아니라 «모른다» 로 적었다(판정 불가 8)
5. **재현성.** 같은 seed 로 다시 돌려도 84쌍 중 12쌍의 판정이 바뀌었고, 모델을 바꾸면 기각 문턱이 바뀐다(\$4.7)
6. **사람 채점자가 한 명이다.** 팩트체커와 사람의 방향 일치 75%($18/24 \cdot \kappa = 0.596 \cdot$ 개발 단계)는 사람 채점 자체의 신뢰도를 모른다
7. **79%(제안 후보 중 무작위 독립 시험이 있는 쌍)는 사후 대조다**(\$1.2)
8. **화면의 %는 보정 전 값이다**
9. **S1 구조 게이트는 약한 대리물이다** — 활성부위 주석이 없으면 단백질 전체 pLDDT 평균을 쓴다. pLDDT 는 결합력이 아니다
10. **자율 재계획이 없다.** 계획은 라우터의 경로 선택이 전부다
11. **안전 게이트는 이름 대조다.** 작성한 우회는 못 막는다. 이 도구는 **의학적 조언이 아니다**(화면과 산출물에 표기)
12. **«먼저 적었다» 의 증거 강도가 명세마다 다르다**(\$3.4) — 본선 홀드아웃 명세는 로컬 봉인 파일 뿐이다
13. **홀드아웃을 두 번 열었다.** 본선 수치는 같은 774쌍의 두 번째 개봉이고, 우리는 첫 개봉 결과를 본 뒤였다. 그 뒤의 모델 · seed 비교도 같은 쌍을 썼다 — 이 자료로 모델이나 문턱을 고르지 않았다(선택은 §2.7 규칙으로 먼저 했다)
14. **«우리 자료에 없음» 은 신규 후보가 아니다.** 발견 지표(Hit@k 등)는 학습 자료의 회상이라 주장하지 않는다

안 한 것 — 그리고 그 이유

항목	상태	이유
도킹(S3)	하지 않았다	제안서가 한 곳(\$3.3)에서는 로드맵, 다른 곳(\$2.4 · \$3.1)에서는 핵심 검증이라 적었다 — 핵심 쪽을 따라 열었고, 라우터가 구조 경로로 보낸 8건과 maraviroc 까지 자료가 9/9 도킹 불가로 답했다 (\$2.3)
전문가 피드백 루프 (HITL)	코드만 있다 · 측정과 시연에서 끔	평가할 전문가가 없다. 반쯤 만든 기능을 수치 없이 내세우지 않는다
특허 자유실시(FTO) 판단	관련 특허 검색 까지	자유실시는 법률 판단이다. 용도 특허 신호는 사전 기준 미달이라 판정에 쓰지 않는다
포켓 예측(fpocket 등)	하지 않았다	UniProt 활성부위 주석을 쓴다. 주석이 없으면 전체 평균(약한 대리물)
개발성 회귀 모델 (LDTS)	하지 않았다	학습 라벨(ChEMBL 개발 단계)이 효능을 섞어 재므로, 학습하면 개발성 점수가 효능을 재게 된다
RAGAS · LLM 심판	하지 않았다	LLM 이 LLM 을 채점하지 않는다 — 원문 문자열 · 수치 대조로 잔다 (\$4.6)
에이전트 프레임워크(LangGraph 등)	의도적으로 안 썼다	관문을 켜고 끄는 반복문 하나가 제거 실험을 만든다
진행 중 임상 예측의 채점	기다린다	결과가 2027년까지 나온다(\$4.8)

9. 재현

```

py -m bioreroute.netcheck                                # 외부 조화가 살아 있는가 (LLM 0회)
py -m bioreroute.run --pair "약물 / 질환"                # 임의 가설을 즉석 검증 (API 키 필요)
py app.py                                                 # 웹 화면 (로컬)
py -m bioreroute.bench.perfcard                          # 4.1 성능 표 (LLM 0회)
py -m bioreroute.bench.calibrate --fit 궤적_0912.json --eval 홀드아웃_본선모델.json --compare-fit bench_r
py -m bioreroute.bench.calibrate --fit 재현성_0920b.json --eval 홀드아웃_본선모델.json # 4.2 민감도 (사
py -m bioreroute.bench.prereg                            # 4.3 사전 기준 대장 집계
py -m bioreroute.bench.fairful --state 상태_홀드본선_B5.json # 4.6 인용
py -m bioreroute.bench.fragility --state 상태_홀드본선_B5.json # 4.7 취약성
py -m bioreroute.bench.labelaudit                       # 3.2 정답표 감사

```

위 명령 중 수치를 내는 일곱(perfcard · calibrate 둘 · prereg · fairful · fragility · labelaudit)은 공개 사본을 새 폴더에 풀어 그대로 돌려 확인했다(LLM 0회). 회귀 시험(py -m bioreroute.tests.test_phase2)과 전 과정 점검(py -m bioreroute.bench.preflight --strict)은 작업 저장소를 기준으로 잴다 — 발표 생성기 · 실행 스크립트 · 배포 사본을 보는 항목이 있어 공개 사본에서는 그 항목이 실패로 뜬다. 회귀 시험 2599건은 작업 저장소에서 셸 수다(시험정본.json).

- **코드** — 공개 저장소(머리의 주소 · 제출 시점 사본)에 배포 묶음 `bioreroute-v69.zip`(코드 · 문서 · 봉인 명세 · 결과 파일)의 내용(개발 중 작업 문서 넷은 뺐다 — 공개 README 에 목록)과, 판정 원본인 상태 파일(한 개 10 MB 안팎) · 봉인 해시의 제3자 타임스탬프(봉인해시_공개등록.txt.ots)가 들어 있다. **캐시는 넣지 않는다** — 없으면 네트워크를 타서 느려질 뿐이고, 넣으면 캐시가 자료원이 되는 사고가 되풀이된다
- **모든 수치는 결과 파일에서 코드가 낸다.** 문서에 옮긴 수는 문서 감사기가 정본과 대조한다
- **자료는 전부 공개 · 무료다.** 회귀 시험 2599건 · 결함 대장 · 사전명세와 봉인 파일 · 실행 매뉴얼(재현절차.md)이 함께 있다

10. 맺음

이 프로젝트가 만든 것은 후보를 잘 고르는 모델이 아니라 **틀렸을 때 그것을 알아채는 절차**다. 그 절차가 우리 자신을 막은 순간을 셋만 꼽는다.

1. 홀드아웃 주지표가 미달했을 때 **기준을 고치지 않았다**(§4.3 · §4.4)
2. 유의한 값이 나왔을 때 사전 지정한 균형 부분집합으로 **교란을 판별하고 버렸다**(§4.9)
3. 헤드라인 지표에 모델 단독 기준선을 나란히 놓자 **우리가 졌다** — 그 표를 성능 절 맨 위에 둔다 (§4.1)

본선 모델로 켄 774쌍에서 이 시스템이 기각한 것의 94.3%는 실제로 실패한 약이었고, 성공한 약을 버린 것은 1.6%였다. 모델 기억을 넘어서지는 못했지만, **모델이 모르는 곳에서 근거를 들고 거른다**(사후 부분집합 · §4.1).

우리가 남긴 것은 성능 수치가 아니라 **그 수치를 믿지 않는 방법**이다.

참고 문헌

1. Wong CH, Siah KW, Lo AW. Estimation of clinical trial success rates and related parameters. *Biostatistics* 2019;20(2):273–286.
2. Harrison RK. Phase II and phase III failures: 2013–2015. *Nat Rev Drug Discov* 2016;15(12):817–818.
3. Yogendrakumar V, Dewar B, McGuinty M, et al. Many trials of hydroxychloroquine for SARS-CoV-2 were redundant and potentially unethical: an analysis of the NIH clinical trials registry. *J Clin Epidemiol* 2022;143:73–80. doi:10.1016/j.jclinepi.2021.11.011
4. Maziarz M, Stencel A. The failure of drug repurposing for COVID-19 as an effect of excessive hypothesis testing and weak mechanistic evidence. *Hist Philos Life Sci* 2022;44(4):47. doi:10.1007/s40656-022-00532-9
5. Morselli Gysi D, do Valle Í, Zitnik M, et al. Network medicine framework for identifying drug-repurposing opportunities for COVID-19. *Proc Natl Acad Sci USA* 2021;118(19):e2025581118.

doi:10.1073/pnas.2025581118

6. Pushpakom S, Iorio F, Eyers PA, et al. Drug repurposing: progress, challenges and recommendations. *Nat Rev Drug Discov* 2019;18(1):41–58.
7. RareAgent: Self-Evolving Reasoning for Drug Repurposing in Rare Diseases. arXiv:2510.05764 (2025).
8. Guney E. Reproducible drug repurposing: when similarity does not suffice. *Pac Symp Biocomput* 2017;22:132–143.
9. CiteCheck: Retrieval-Grounded Detection of LLM Citation Hallucinations. arXiv:2605.27700.
10. Scardino V, Di Filippo JJ, Cavasotto CN. How good are AlphaFold models for docking-based virtual screening? *iScience* 2023;26(1):105920. doi:10.1016/j.isci.2022.105920
11. Platt JC. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: *Advances in Large Margin Classifiers*. MIT Press; 1999:61–74.
12. Walsh M, Srinathan SK, McAuley DF, et al. The statistical significance of randomized controlled trial results is frequently fragile: a case for a Fragility Index. *J Clin Epidemiol* 2014;67(6):622–628.
13. Baell JB, Nissink JWM. Seven year itch: pan-assay interference compounds (PAINS) in 2017 — utility and limitations. *ACS Chem Biol* 2018;13(1):36–44.
14. Lipinski CA, Lombardo F, Dominy BW, Feeney PJ. Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings. *Adv Drug Deliv Rev* 2001;46(1–3):3–26.
15. Jumper J, Evans R, Pritzel A, et al. Highly accurate protein structure prediction with AlphaFold. *Nature* 2021;596:583–589.
16. Rena G, Hardie DG, Pearson ER. The mechanisms of action of metformin. *Diabetologia* 2017;60(9):1577–1585.
17. Brown AS, Patel CJ. A standard database for drug repositioning. *Sci Data* 2017;4:170029.
18. CiteGuard: Faithful Citation Attribution for LLMs via Retrieval-Augmented Validation. arXiv:2510.17853.
19. Swanson DR. Fish oil, Raynaud's syndrome, and undiscovered public knowledge. *Perspect Biol Med* 1986;30(1):7–18.
20. Guyatt GH, Oxman AD, Vist G, et al. GRADE guidelines: 4. Rating the quality of evidence — study limitations (risk of bias). *J Clin Epidemiol* 2011;64(4):407–415. doi:10.1016/j.jclinepi.2010.07.017
21. Mitigating LLM-based p-Hacking by Preregistering for the Next LLM. arXiv:2606.27687.
22. Predicting LLM Safety Before Release (OSF 사전등록 osf.io/un3he). arXiv:2607.07184.
23. Mallen A, Asai A, Zhong V, Das R, Khashabi D, Hajishirzi H. When not to trust language models: investigating effectiveness of parametric and non-parametric memories. In: *Proceedings of ACL 2023*. arXiv:2212.10511.