

Bio-ReRoute — 반증 우선 약물 재창출 에이전트

연구 · 기술 보고서

제4회 AI 신약개발 경진대회 · 공모분야 4 황승우 (1인) · 2026년 9월 · 코드 `bioreroute-v69.zip` · 회귀 시험 2661건

- 데모 — <https://james7371-bio-reroute.static.hf.space> (키 없이 열린다 · 판정은 미리 구워 둔 스냅샷이다)
 - 코드 — <https://github.com/hwangjames7371/Bio-ReRoute-public> (제출 시점 사본 · 코드 · 봉인 명세와 제3자 타임스탬프 · 결과 파일 · 결함 대장)
-

0. 요약

생성형 AI 는 약물 재창출 후보를 **만드는 비용**을 거의 0으로 만들었다. 남은 병목은 그럴듯하지만 틀린 후보를 값싸게 걸러내는 일이다[4]. Bio-ReRoute 는 그 일만 한다 — 가설(약물 · 질환)을 받아 공개 문헌 · 임상 등록부 · 화학 정보에서 **반증을 먼저 찾고**, 근거가 모자라면 판정하지 않고 **보류**한다. 판정마다 근거 문장 원문 · PMID · 가중치를 남긴다.

평가는 «얼마나 잘 찾았나» 가 아니라 **기각이 맞았나 · 맞는 것을 버렸나 · 신뢰도가 정직한가로** 한다. 사전 기준이 있는 실험은 모두 결과를 보기 전에 기준을 적고 해시로 봉인한 뒤 돌렸고, 그 밖의 분석은 **사후**라고 표시했다.

표기 — 수 뒤 대괄호 안의 두 수(예: 79% [52–92])는 95% 신뢰구간이고, 숫자 하나(예: [4])는 참고문헌 번호다. TN · TP 는 정답표의 음성 · 양성이다 — 효능 실패로 중단된 임상의 약-적응증 쌍(TN)과 승인된 적응증 쌍(TP).

	결과
본선 홀드아웃 774쌍 (실패 임상 387 · 승인 적응증 387 · 봉인 · 두 번째 개봉 — 첫 개봉은 개발 단계 모델 · gpt-5.6-terra)	사전 지정 주지표(기각의 시간 구조 — 시험 종료 1년 전까지의 문헌만 볼 때의 기각 재현율 ÷ 전 기간 기각 재현율 $\leq 0.50 \cdot \$4.4$) 0.939 — 미달 . 부차 지표: 기각 정밀도 94.3% (99/105 · 근거로 한 기각만 66/70 = 94.3%) · 성공한 약을 버림 1.6% (6/387) · 보류(«모른다») 61.1%
같은 모델을 문헌 없이 쓴 기준선(모델 단독)과 비교	전체에서는 모델 단독이 더 거른다(기각 정밀도 96.8% 대 94.3% · 기각 재현율 31.5% 대 25.6%) — 우위를 주장하지 않는다 . 모델 단독이 «모름» 이라 답한 445쌍(정의상 모델 단독은 거르지 않는다 · 그중 실패 임상 쌍 44.7%)에서 파이프라인이 41건을 기각해 38건 적중 — 그중 근거로 한 기각은 16건(15건 적중)이고 25건은 약 이름이 문헌에서 안 잡혀 끊었다(사후)
보정 (Brier · 낮을수록 좋다)	파이프라인 0.219 · 모델 단독 0.218 · 널 0.250 (774쌍). 개발 벤치마크(층 A)로 맞춘 Platt 보정 후 파이프라인 0.220 → 0.212(층 A 와 겹치는 4쌍을 뺀 770 쌍). 모델 단독과는 구별되지 않는다
인용 검증 (본선 실행 전수)	LLM 이 낸 인용 6,657건 중 원문 대조까지 간 것이 2,129건(32.0%)이고, 그중 2,128건이 초록 원문에 실재했다(99.95%)
전향 봉인 예측	결과가 아직 없는 임상 60건 + 무작위 음성대조 20쌍 봉인(개발 단계 모델) · 음성대조에 «유망» 0/20
사전명세	31회 봉인 · 사전 기준 42개 — 통과 20 · 미달 14 · 판정 불가 8 · 결과를 본 뒤 기준을 낮춘 기록은 없다
스스로 찾은 결함	결함 387건 공개(측정 · 문서 · 절차) · 회귀 시험 2661건

가장 중요한 한 줄 — 우리는 반증하는 시스템을 만들었고, 그 절차를 우리 자신의 측정에 먼저 적용했다. 이 보고서의 수치 가운데 상당수는 그 절차가 우리 주장을 **깎은** 결과다.

개발 이력 — 예선 기획서를 준비하던 7~8월에 프로토타입을 만들었다. 본선 개발 기간(9월 7일~10월 2일)에는 주최측 모델로 옮기고, 봉인 홀드아웃을 그 모델로 다시 켜고, 전문 읽기를 새로 만들고, 결함을 고치고 검증했다. 이 보고서의 수치는 본선 모델로 켜진 것이 기본이고, 개발 단계 모델로 켜진 것은 그렇게 표시했다.

1. 문제

1.1 병목은 후보가 아니라, 틀린 후보를 버리는 일이다

임상에 진입한 신약의 약 86%가 승인에 실패하고[1], 2·3상 실패의 사유는 효능 52% · 안전성 24%다 [2]. 재창출은 안전성이 이미 확인된 약에서 출발하므로[6] 남는 병목이 정확히 **효능**이다.

틀린 가설 하나의 비용은 실측된다. 2020년 2~11월 하이드록시클로로퀸(HCQ)으로 코로나19 를 치료하려는 시험이 NIH 등록부에만 **206건** 등록됐다. 11월 기준 135건이 진행 중, 22건이 완료, 46건이 중

단·종료였고(초록의 수 그대로 · 셋의 합은 203), 저자들은 의료계가 정치적 관심에는 빨리, 효능이 없다는 근거에는 늦게 반응했다고 결론지었다[3].

이 문제 정의는 우리 것이 아니다. Maziarz & Stencel 은 같은 HCQ 사례로 코로나 재창출의 실패를 **과도한 가설 검정과 약한 기전 근거로 설명하고, 음성(반증) 기전 근거를 함께 보라고 처방했다**[4]. 우리 몫은 그 처방을 **후보마다 자동으로 실행하는 절차로 만들고, 그 절차가 얼마나 맞는지 미리 정한 기준으로 잴** 것이다.

1.2 반증 근거는 얼마나 있는가 — 두 숫자

ClinicalTrials.gov 에서 종료(Terminated)된 시험 34,067건(이하 종료 시험)을, 정답표의 중단 사유를 가른 것과 같은 분류기로 전수 분류했다(LLM 0회).

종료 시험 전수	34,067	
운영상 중단 (모집 · 자금 · 공급 · COVID)	16,224	47.6%
사유 불명 · 미기재	13,745	40.3%
약물 개입 없음	2,198	6.5%
안전성 중단	455	1.3%
효능 실패로 중단	1,445	4.2%
<- 그중 대조 가능(무작위 · 2상 이상) 781 (54%) -> 전체 대비 2.3%		

종료 시험 100건 중 반증에 쓸 수 있는 것은 2건이다. 중단 사유가 자유 기술이라 4.2%는 하한이다.

그런데 누군가 **실제로 제안하는 후보**에서는 다르다. LLM 이 제안한 후보를 같은 도구로 재면 —

	무작위 독립 시험이 있는 쌍의 비율(결과 방향과 무관 — 반증에 쓸 수 있는 상한)	그 약들의 문헌 중앙값
LLM(개발 단계 모델)이 제안한 후보 14쌍	79% (11/14) [52–92]	259
홀드아웃 TN 384쌍 (조회 실패 3 제외)	39% (150/384) [34–44]	9
개발 벤치마크 TN 42쌍	29% (12/42)	40

Fisher $p = 0.004$ · 사후 검정력 88%(관측 효과 기준 — p 와 같은 정보다). 생성기는 유명한 약을 내고, 유명한 약에는 시험이 있다 — 그 시험이 반박인지 지지인지는 이 표가 세지 않는다.

⚠ **이 대조는 사전 지정이 아니다.** 2.3%를 본 뒤에 다른 분모로 다시 재서 찾은 값이다. 이 보고서에는 이런 탐색적 검정이 여럿 실려 있어, $p = 0.004$ 를 다중비교까지 견딘 확증으로 읽지 않는다 — **방향을 보여 주는 관찰**로만 쓴다. 그래서 두 숫자를 같이 적는다 — 2.3%만 말하면 제안되는 후보를 감추고, 79%만 말하면 모집단을 감춘다.

1.3 그리고 근거는 늦게 온다

개발 벤치마크의 효능 실패 쌍에서 반박 문헌의 출판 시점을 대조하면 **12건 중 11건이 시험 종료 이후 이거나 같은 해에** 나왔다(예외는 erlotinib 한 건 · 정의상 반박은 그 시험의 보고서라 늦게 나오기 쉽다). 판정에 쓸 문헌을 시험 종료 1년 전 · 3년 전까지로 막으면(시점 차단) 기각 재현율이 17% → 2% → 0% 로 무너진다 (개발 단계 모델 gpt-5.4-mini).

두 사실은 함께 참이다 — 반박 근거는 **비싼 시험을 치른 뒤에야 생기고(11/12), 일단 생기면 유명한 약에 쌓인다(79%)**. 그래서 이 시스템이 하는 일은 새 약을 예언하는 것이 아니라, **이미 쌓인 반박을 지금 제안된 후보에 되돌려 적용하는 것이다**. 본선 홀드아웃에서 이 시간 구조를 사전 기준으로 다시 켜고 미달했다 — 근거로 한 기각만 따로 세면 무너졌지만 총량으로 센 사전 지표는 0.939 였다(\$4.4).

2. 시스템

2.1 반증 깔때기 — 값싼 결정론부터

약자	관문	하는 일	LLM
F0	근거 실재성	약물 이름이 문헌에 있는가(실체) · 그 약물-질환 쌍에 문헌이 있는가(연결). 약물은 있는데 쌍 문헌만 없으면 기각하지 않고 신규성 신호 로 표시한다[19]	없음
L2	팩트체커	LLM 이 인용한 문장이 초록에 실제로 있는가 · 결과를 진술하는가 · 그 약을 지목하는가 → 지지·반박 방향과 가중치	사용
R	기전 라우터	직접/간접 × 병원체/숙주로 분류해 검증 경로 를 정한다 — 탈락이 아니라 분기다	사용
S1	구조 신뢰도	구조 경로일 때만 — AlphaFold pLDDT[15]. 결합력이 아니다	없음
S2	리간드 개발성	PubChem → RDKit: PAINS[13] · Ro5[14] · hERG · DILI 경고	없음
SK	회의주의자	반박 문헌을 능동 으로 더 찾아 읽는다	사용
F	전문 읽기	논문 전문에서 저자가 스스로 적은 한계를 읽어 근거 가중치를 감쇠한다(지지 · 반박 양쪽)	사용
REG	등록부	ClinicalTrials.gov 에서 같은 약 · 질환의 실패 임상을 찾아 팩트체커로 읽는다	사용

LLM 앞에서 거르는 값싼 관문은 F0 하나다 — S1 · S2 는 거르지 않고 표시만 한다(\$2.8). 관문마다 켜고 끌 수 있어 **제거 실험이 반복문 하나로** 돈다.

구성	컨 것	쓰임
B0	없음 — 같은 모델에게 문헌 없이 «성공 · 실패 · 모름» 을 묻는다	모델 기억 기준선
B1 ~ B4	문헌 검색·팩트체커 → + F0 → + 회의주의자 → + S2	제거 실험
B5	문헌 검색·팩트체커 · F0 · 라우터 · S2 · 회의주의자	평가 구성 — 이 보고서의 주 수치
B6	B5 + 등록부	등록부 실험
B7	B6 + S1	벤치마크에 쓰지 않았다
B8	B7 + 전문가 거절 목록(HITL)	운용 구성 — 재현 가능한 측정이 아니라 벤치마크에 쓰지 않는다
B5F	B5 + 전문 읽기	전문 읽기 실험(§4.3 · 판정 불가)
B5SF	B5 + S1 + 전문 읽기	시연 구성 — 데모가 쓰는 것

평가 구성 B5 에는 S1 · 등록부 · 전문 읽기가 없다. 넣으면 봉인된 수치가 다른 시스템의 수치가 되므로 따로 잰다(§4.3).

2.2 판정 — 로그오즈를 쌓고, 모르면 기권한다

판정 확률은 규칙 기반 로그오즈 합이다 — LLM 이 확률을 직접 정하지 않는다. 다만 근거 한 건의 가중치는 연구 유형과 LLM 이 매긴 등급(규모 · 결정성 · 확신 · 확실성), 인용 검증 결과를 곱해 정하므로 LLM 은 등급을 통해 무게에 들어간다 (같은 논문의 가중치가 실행마다 흔들리는 이유가 이것이다 · §4.7). 같은 시험의 본 논문 · 추적 · 하위분석(같은 NCT)은 한 번만 세고, 상관된 근거는 감쇠하며, 확신에는 상한을 둔다. 지지와 반박이 대등하면 기각하지 않고 조건부로 둔다.

로그오즈를 쌓지 않고 0%로 끊는 경우는 둘뿐이다 — ① 약물 이름 자체가 문헌에서 안 잡힐 때(F0 · 실제로는 임상시험 개입명이 코드나 용량 표기라 문헌 검색에 안 걸리는 경우가 대부분이다) ② 확증 임상의 결정적 음성이 두 건 이상이고 같은 급의 지지가 없을 때(이것을 거부권이라 부른다). 그 밖에는 근거를 쌓아 판정하고, 근거가 얇으면 보류한다. 근거 없이 기각하는 것은 반증이 아니라 사전확률이기 때문이다 — ①은 이 원칙의 예외라 그 몫을 §4.1 에서 따로 센다.

2.3 기전 라우터 — 언제 도킹하지 않는가

경로	예	타당한 검증
직접 · 병원체	RdRp 억제제	구조 신뢰도(S1) → 도킹 후보
직접 · 숙주	바리시티닙(JAK)	임상 · 발현 근거 — 바이러스 단백질 도킹은 무의미하다
간접	메트포르민(Complex I 억제 → AMPK 활성화[16])	네트워크 · 임상 근거 — 도킹은 범주 오류다
오프타겟 · 불명	—	근거 경로

이 전제는 우리 것이 아니다 — 세포 실험에서 감염을 줄인 약 77개 중 76개가 SARS-CoV-2 가 결합하는 (숙주) 단백질에 붙지 않아, 도킹으로는 찾을 수 없다[5]. 우리 몫은 그 판단을 **후보마다 자동으로 내리고, 안 돌린 이유를 판정 기록에 남기는 것**이다.

분기가 실제로 열리는지 봉인하고 졌다. 병원체 표적 8쌍(remdesivir/RdRp · nirmatrelvir/3CLpro ...)과 숙주 · 간접 8쌍(baricitinib/JAK · camostat/TMPRSS2 · maraviroc/CCR5 ...)을 섞었다. 대조군 8쌍 중 7쌍이 감염병(COVID-19 4 · HIV 2 · 말라리아 1)이라 «감염병이면 구조» 라는 지름길은 여기서 반드시 틀린다. 결과 — 병원체 **8/8** 구조 경로 · 숙주 · 간접 **0/8** · Fisher p = 0.0002(사전 기준 통과 · 봉인 해시를 실행 전에 제3자 타임스탬프로 등록했다 · 개발 단계 모델 · 온도 0).

그리고 통과한 쪽도 도킹까지 가지 못했다. 라우터가 구조 경로로 보낸 8건과 규칙을 통과한 maraviroc 1건에 실험 구조를 대 보니 **9/9 가 봉인한 채택 규칙을 넘지 못했다.** 가장 흔한 사유는 «도킹할 분자가 그 자리에 오는 분자가 아니다»(전구약물 · 활성형 · 공유결합 부가체 · 4건)였고, 나머지는 자리 미형성 1 · 구조 자료 없음 3 · 포켓 정의 불가 1 이다(maraviroc 은 활성부위 주석이 없어 대장에서 판정 불가). 도킹 엔진은 설치하지 않았다 — **도킹은 한 번도 돌리지 않았고, 그것이 결과다.**

S1(pLDDT)은 **필요조건**으로만 쓴다 — 도킹 성능이 가장 크게 떨어진 AlphaFold 모델 다섯 중 넷에서 결합 부위 잔기의 pLDDT 가 모두 70 이상이었다는 보고가 있다[10]. 활성부위 주석이 없는 표적은 단백질 전체 평균을 쓰고, 그것이 약한 대리물이라고 화면이 적는다.

2.4 인용 검증 3점 — 그리고 감사 추적

LLM 이 근거로 든 문장마다 셋을 확인한다.

	확인	아니면
①	그 문장이 초록 원문에 실제로 있는가	무관으로 강등(가중치 0)
②	그 문장이 결과를 진술하는가	감쇠
③	그 문장이 그 약을 지목하는가	감쇠(간접 근거)

실제 사고 셋이 이 관문을 만들었다 — `interferon beta-1a` / `크론병` 이 **natalizumab** 메타분석을 근거로 «유망 94%» 를 받았고, `pramipexole` / `ALS` 가 거울상체 **dexpramipexole** 의 3상을 근거로 삼았고, «측

정 방법» 같은 문장이 높은 가중치로 채택됐다. **셋 다 실재하는 문장이었다.** 지어낸 것이 아니라 **관계가 틀렸다.**

판정은 숫자 하나로 끝나지 않는다. 화면과 결과 파일에 **근거 문장 원문 · PMID · 연구 유형 · 가중치 · 관문별 결과**가 남고, 산출물에는 **AI 생성 표기**와 분업(후보 · 요약 · 기전 분류 · 근거 등급은 LLM · 인용은 원문 대조를 통과한 것만 · 확률은 규칙 기반 합)이 붙는다. 틀렸을 때 **어디서 틀렸는지** 그 자리에서 보이게 하는 것 — 감사 추적이 이 시스템의 본체다.

2.5 자율성 — 오류를 알아채고, 고칠 수 있으면 고친다

고친다	알아채고 판정을 멈춘다
인용이 초록에 없다 → 가중치 0	PubMed 조회 실패 → 보류(0건으로 세지 않는다)
인용이 다른 약을 가리킨다 → 감쇠	AlphaFold 응답 없음 → 경로를 바꾸지 않는다
같은 시험의 본 논문 · 추적 · 하위분석 → 시험 번호 (NCT)로 하나만 센다	부작용 신호의 분모가 0 → 계산 불가(무한대를 신호로 쓰지 않는다)
지지 · 반박이 대등 → 조건부로 재분류	분류가 전부 실패 → 판단 자체를 거부(종료 코드 1)
근거가 철회됐다 → 근거에서 제외	

조회 실패를 0건으로 세면 네트워크 장애가 «발견» 이 된다. 실제로 한 도구가 조회 실패를 0건으로 합산해 «반증 근거의 부재는 구조적이다» 라는 결론을 낸 적이 있다 — 하필 우리 논지를 지지하는 방향이었다(§5). △ 이 방어가 F0 의 두 번째 조회(약물 실재 확인)에는 늦게 붙어, 본선 실행에서 1건이 조회 한도 초과(HTTP 429) 인데도 «문헌 없음» 으로 기각됐다 — §4.1 의 기각 105건에 들어 있다(실행 뒤 고쳤다 · 결함 대장 329번). 메타분석은 시험 번호가 없어 위의 중복 제거에 걸리지 않는다(§5).

하지 않는 것도 적는다. 실패한 뒤 전략을 새로 짜는 **자율 재계획은 없다.** 라우터가 후보별로 검증 경로를 고르는 것이 계획의 전부다. 궤적을 세어 보니 «관문을 스스로 건너뛴다» 로 보이던 기록의 대부분 (개발집합 실행에서 건너뛴 88건 중 84건)은 **설정에서 끈 것이었다** — 계측을 고쳐 돌을 나눠 남긴다. 전문가 거절 목록(HITL)은 코드가 있지만 평가할 전문가가 없어 측정과 시연에서 껴다.

2.6 도구와 자료원 — 전부 공개 · 무료

자료원 · 도구	쓰는 곳
PubMed (E-utilities)	F0 · 팩트체커 · 회의주의자 · 시점 차단
ClinicalTrials.gov API v2	등록부 · 종료 시험 34,067건 전수 분류 · 정답표(TN)
RepoDB[17]	정답표(TP · 승인 적응증)
PubChem → RDKit	S2 개발성(PAINS · Ro5 · hERG · DILI 경고) · 분자 지문
UniProt → AlphaFold DB	S1 구조 신뢰도(pLDDT) · 3Dmol.js 구조 표시(색은 예측 신뢰도이지 결합력이 아니다)
RCSB PDB · UniChem	실험 구조 · 종 대조(도킹 가능 여부 판단)
openFDA FAERS · SIDER	역발상 발굴(부작용 신호)
ChEMBL · SureChEMBL	저분자 한정 · 관련 특허 검색(자유실시 판단이 아니다)
DRKG	그래프 검색(라이선스 CC BY-NC)

외부 조회가 살아 있는지는 `netcheck` 가 LLM 0회로 확인한다. RDKit 이 없으면 S2 는 **SKIP** 으로 표시된다 — 숨기지 않는다.

2.7 모델 선택 — 왜 `gpt-5.6-terra` 인가

주어진 선택지. 본선 크레딧은 `gpt-5.6-sol` · `gpt-5.6-terra` · `gpt-5.6-luna` 셋을 지원했다. 개발 단계에 쓰던 `gpt-5.4-mini` 는 이 크레딧으로 쓸 수 없다. `gpt-6` 계열 둘은 주 평가 실행 뒤에 추가돼 쓰지 않았다.

판정 성능으로 고르지 않는다. 여러 모델로 벤치마크를 돌려 가장 잘 맞는 것을 고르면 결과를 보고 시스템을 고른 것이 된다. 그래서 고르는 규칙을 실측 전에 명세에 적었다(사전명세_모델교체_본선.md §4) — **0단계 자격:** JSON 형식 준수 90% 이상 · **1단계 순위:** ① 응답 지연 중앙값 → ② 출력 토큰량 → ③ 이름순. 판정용이 아닌 형식 확인 프롬프트로 모델당 30회를 두 차례에 나눠 잤다.

모델	JSON 준수	지연 중앙(초)	출력 토큰(20회 합)
sol	20/20	2.12	375
terra	20/20	1.89	359
luna	20/20	1.74	635

셋 다 자격을 통과했다. 지연은 두 번 잤는데 **1 · 2위가 뒤집혔다**(1차 terra 1.54초 · 2차 luna 1.74초 — 위 표는 2차). 명세는 «순위가 바뀌면 적는다» 까지만 정했고, 우리는 두 측정이 갈리지 않는다(순열검정 $p = 0.543$)고 보고 **동물로 처리해** ②로 내려갔다 — **이 동물 처리는 명세에 없던 판단이다.** ②에서 **terra 의 출력 토큰이 luna 의 1/1.77** 이었다. 규칙을 글자대로 2차 측정에만 대면 luna 가 1위다. sol 과는 ① · ② 둘 다 terra 쪽이 짧았지만, 지연 차이는 보정한 기준을 넘지 못했다.

뒤에 낸 것도 같은 쪽이었다. 세 모델 모두 temperature=0 을 거부해 재현성을 따로 잰다 — 같은 질문을 다섯 번씩(소수 · 분류 · 자유 요약) 물었을 때 **terra 만 세 유형 모두 다섯 번 같은 답**이었다(sol 두 유형 · luna 한 유형). 그래서 seed = 42 를 고정해 쓴다(seed 를 고정하면 세 모델 모두 다섯 번 같은 답 · 보장이 아니라 재현 시도다). 외부 공개 순위(IQ 시험)도 terra > sol > luna 였지만, 우리 과제와 구성 개념이 달라 선택 근거로 쓰지 않았다.

△ **말하지 않는 것** — «terra 가 우리 과제에서 가장 정확하다» 는 재지 않았다. 규칙의 봉인(해시)은 선택 뒤에 걸려서, «실측 전에 적었다» 의 증거는 우리 기록뿐이다(§3.4). 그리고 봉인 다음 날 **그 명세 본문에 문단을 덧붙여서** 1차 봉인 본문을 되살릴 수 없다(다시 봉인하고 두 해시를 남겼다 · §4.3) — 이 명세로 낸 수치를 인용할 때는 이 사실을 같이 적는다. 사후에 네 모델을 같은 홀드아웃에 돌린 결과는 §4.1 이다 — «모름» 문항의 순위 지표는 모델 간에 구별되지 않았고, **기각을 많이 하는 정도는 sol 한 모델에서만 되풀이해 달랐다** (terra 와 luna 는 갈리지 않았다 · §4.7). 모델을 바꾸면 기각 문턱을 다시 확인해야 한다.

2.8 리소스 — 크레딧은 살아남은 후보에만

	실측
본선 홀드아웃 774쌍 한 번 (B0 + B5)	523만 토큰 · 호출 1,093회 · 쌍당 약 6,800 토큰
같은 774쌍 시점 차단 재실행	457만 토큰 · 호출 996회
단계별 토큰 (위 첫 실행)	팩트체커 292만 · 회의주의자 201만 · 라우터 15만 · 모델 단독 15만
본선 기간 합 (우리 계량기)	약 4,960만 토큰 · 호출 약 1만 회 — 비용 기록을 남긴 실행의 합이다: 774쌍 전체 실행 9번(위 둘 · 다른 모델 둘 · seed 복제 다섯) · 개발 벤치마크 84쌍 재실행 · 표적 재시험. 비용 기록이 없는 호출(계량을 붙이기 전 첫 353회 · 데모 · 점검)은 빠져 있어 실제 사용은 이보다 많다. 공급자 쪽 잔량 표시는 첫 주에 갱신을 멈춰(09-13 실측) 쓰지 않았다
LLM 0회로 낸 것	종료 시험 34,067건 분류 · 인용 충실도 · 판정 취약성 · 보정 · 정답표 감사 · 누출 측정 · 문서 감사
유료 데이터 · GPU	0원 · 0개 — 도킹을 돌리지 않는다
폭주 방지	실행 한 번의 LLM 호출 상한(기본 60회 · 벤치마크 실행은 명시해 올린다) · 라이브 실행 하루 300회 상한 · 토큰 계량기(우리가 직접 센다)
모델 교체	역할별 모델을 설정 한 줄로 바꾼다 — terra ↔ luna · sol 98쌍에서 검증 경로 불일치 각 1/98 · 같은 모델을 두 번 돌린 잡음(1/98 · 0/98)과 같은 수준 · 5분류 일치 κ 0.825 · 0.849 (명세는 §2.7 의 그것 — 봉인 뒤 본문이 고쳐졌다)

크레딧이 어디로 갔나 — 새 구성을 찾는 데가 아니라 **같은 774쌍을 조건만 바꿔 다시 재는 데** 갔다. 전체 실행 9번 중 헤드라인 한 번을 뺀 여덟 번 — seed 복제 다섯 · 다른 모델 둘(재현성)과 시점 차단

하나(미리 건 주지표) — 이 합의 **85%**다. 헤드라인 한 번만 돌렸다면 약 10분의 1로 끝났고, 그 대신 «두 번 재면 같은 답이 나오는가»와 «반증 근거는 늦게 오는가»를 못 적었다(\$4.4 · \$4.7 · \$8 한계 5).

비용 대부분은 문헌을 실제로 읽는 두 단계(팩트체커 · 회의주의자)에 든다. LLM 을 부르기 전에 거르는 값싼 관문은 F0(문헌 실재성) 하나다 — 실행 순서는 F0 → 팩트체커 → 라우터 → 구조(S1) → 약물다움(S2) → 회의주의자이고, S1 · S2 는 거르지 않고 표시만 한다. 그래서 F0 에서 끊긴 후보에는 LLM 비용이 한 번도 들지 않는다. 확장은 자료원이 어댑터로 분리돼 있어 새 DB 가 파일 하나이고, 새 구성은 설정 한 줄이다.

3. 평가 설계

3.1 원칙 — 무엇을 먼저 보나

1. **기각이 맞았나** — 기각 정밀도(기각한 것 중 실제로 실패한 약)
2. **맞는 것을 버렸나** — 승인된 약을 기각한 비율
3. **모르면 모른다고 하나** — 보류 비율과 Brier 를 **널 모형(늘 기저울)**과 나란히 적는다
4. **모델 기억이 아닌가** — 같은 모델을 문헌 없이 쓴 기준선(B0)을 같은 쌍에 나란히 적는다

본선 홀드아웃 명세가 미리 건 **주지표는 기각의 시간 구조(\$4.4)**이고, 위 넷은 그 옆에 적는 부차 지표다(\$4.1).

AUROC 는 보조다. 시스템은 «보류»로 기권하는데 AUROC 는 기권을 0.5 쪽으로 뭉개 정보를 버린다. ECE 도 쓰지 않는다 — 기저울이 0.5 인 평가 집합에서는 «늘 0.5»라고 답하는 널 모형의 ECE 가 0 이다.

3.2 자료

집합	구성	쓰임
개발 벤치마크 (층 A)	TN 42 (효능 실패로 중단된 임상 의 약-적응증) · TP 42 (RepoDB 승인) · 문헌량을 맞춰 짝지음	개발 · 보정 적합
봉인 홀드아웃	TN 387 (ClinicalTrials.gov 효능 실패 중단 시험에서 새로 수확 · 수확분을 약물 단위 해시로 개발용 · 봉인용으로 나눔 · 둘의 교집합 0) · TP 387 (RepoDB 승인) · 두 번 열었다 — 첫 개봉은 개발 단계 모델, 두 번째 개봉이 제출 모델(\$4.1)	주 평가 · 결과를 보기 전에 동결
전향 봉인	진행 중 임상 60건(1차 완료 후 11~13개월 · 결과 미게시) · 무작위 음성대조 20쌍 · 개발 단계 모델	결과가 나오면 대조
생성 실험	질환 12개 → 후보 340건 · 확장 질환명 37개(동의어 포함) → 후보 1,074건 · 둘 다 개발 단계 모델	생성기 관찰 (\$4.5)

누출 차단 — 라벨이 된 시험과, 색인으로 찾을 수 있는 그 결과 논문은 근거에서 뺀다(본선 실행 294 건). 라벨 시험 387건 중 결과 논문 색인이 없는 211건은 못 막으므로 **«볼 수 있는 누출만 제거했다»**가 정확한 문장이다. 차단이 새는지는 첫 개봉(개발 단계 모델)에서 실측했다 — 색인된 80건 중 6건

(7.5%)이 라벨 출처 논문을 읽고 있었다. 제출 모델 실행에서는 이 누출 측정을 다시 하지 않았다. 6건 모두 기각이었고 그중 5건은 그 논문이 결정적이었다. 주지표 판정(미달)은 바뀌지 않았다(\$5).

정답표 감사 — 개발 벤치마크의 TN 후보 49건의 ClinicalTrials.gov 원문을 전부 읽었다. **효능 실패가 아닌 것이 18/49 = 37%** 였다(안전성 · 독성 11 · 모집 · 사업상 5 · 다른 연구 근거 2). 분류 규칙을 코드로 고정한 값이고, 즉석 계산으로는 43%가 나왔다. warfarin 한 건이 문제를 보여 준다 — 시험은 치료군 사망 초과로 멈췄는데 시스템은 효능 근거로 기각했고, 그 근거 문장은 안전성 이야기였으며 내용은 «차이가 없다» 였다. **맞은 것이 아니라 우연히 같은 칸에 떨어졌다.**

(개발 단계 모델)	기각 정밀도	기각 재현율
전체 TN 42 — 주 수치	7/7 = 100% [65–100]	17% [8–31]
효능 실패만 27 — 사후 민감도 분석	5/5 = 100% [57–100]	19% [8–37]

방향은 살아남고 하한만 내려간다. 우리가 쟀 것은 «효능 실패를 걸렀는가» 가 아니라 «어떤 이유로든 중단된 시험을 걸렀는가» 에 가깝다. **정답표는 고치지 않는다** — 결과를 보고 정답을 고치면 측정이 아니라 조작이다. 실패 모드별 라벨링은 다음 명세에서 사전에 한다. 봉인 홀드아웃의 TN 은 이 감사를 하지 않았다 — 등록 미달을 효능 실패로 잘못 분류한 것만 썼다(봉인 짝의 0.5%).

«모름» 부분집합 — B0 가 «모름» 이라 답한 문항. 라벨이 아니라 **모델의 출력만으로** 고르므로 «모델이 답을 내놓지 않은 곳» 을 재는 데 쓴다 — 기억이 없는 것과 답을 거절한 것을 가르지는 못한다(잘 알려진 승인 적응증에도 «모름» 이 나온다). 결과를 본 뒤 정했으므로 **사후**라고 적는다.

3.3 사후편향을 빼는 세 단계

단계	방법	남는 사후편향	결과
① 후향 홀드아웃	결과를 보기 전에 동결한 774쌍 — 헤드라인은 제출 모델의 첫 실행(같은 홀드아웃의 두 번째 개봉)이고, 그 뒤 seed 복제 · 시점 차단 · 다른 모델 둘을 같은 홀드아웃에 더 돌렸다	있다 — 결말이 모델 학습 자료에 있을 수 있고, 첫 개봉 결과를 우리가 이미 봤다	\$4.1
② 시점 차단	시험 종료 1년 전까지 발행된 문헌만 쓴다	일부 — 모델이 결말을 기억할 수 있다	\$4.4
③ 전향 봉인	결과가 아직 없는 임상을 예측하고 봉인한다	적다 — 그 시험의 논문 27편은 근거에서 뺐지만, 모델 사전 학습에 중간 정보가 있을 수 있다	\$4.8

②의 한계를 줄이려고, 판정은 검색된 근거 사슬로만 계산하고 차단 시점 이후에 발행된 PMID 는 근거로 인정하지 않는다.

3.4 사전명세 — 결과를 보기 전에 기준을 적는다

사전 기준이 있는 실험마다 **주지표 · 성공 기준 · 예측 · 반증 조건**을 먼저 적고 sha256 으로 봉인한 뒤 돌렸다. 봉인한 명세 31개에서 나온 기준을 하나도 빠지 않고 대장(사전기준_대장.csv)에 적었고, 대장과 문서의 집계가 같은지는 코드가 본다. 결과는 §4.3.

«먼저 적었다» 는 증거의 강도는 셋이다 — 섞어 적지 않는다.

강도	무엇이 증명하나	해당
강	봉인 해시를 제3자 타임스탬프(OpenTimestamps · 비트코인 블록)로 등록	라우터 분기 · 등록부 실험(등록 당시 미실행) · 전향 봉인 예측 80건(예측도 등록도 임상 결과가 나오기 전)
중	명세와 결과의 git 기록 — 커밋 시각은 우리 컴퓨터가 만든 것이다. 작업 저장소는 비공개이고, 공개 저장소(제출 시점 사본)에 명세 · 결과 파일의 커밋 기록을 뽑아 싣는다(커밋기록_요약.txt)	대부분의 명세
약	로컬 봉인 파일뿐 — 봉인 파일 뒤에 실행했지만 커밋은 실행 뒤였다(저장소 잠금 사고로 커밋이 엇새 밀렸다)	본선 홀드아웃 · 시점 차단 명세 · 모델 선택 규칙(봉인이 선택 뒤)

본선 홀드아웃 명세 첫머리에는 «초안이다 · 아직 봉인하지 않았다» 가 남아 있다 — 그 본문 그대로를 09-19 밤에 봉인했고, 봉인 뒤 본문을 고치지 않는다는 규칙 때문에 그대로 두었다.

4. 결과

4.1 본선 홀드아웃 774쌍 — 파이프라인과 모델 단독

수는 `py -m bioreroute.bench.perfcard` 가 결과 파일(홀드아웃_본선모델.json)에서 낸다 — 손으로 옮기지 않았다. 발표의 성능 장도 같은 함수를 부른다. 모델 `gpt-5.6-terra` · seed 42 · 결과를 보기 전에 봉인한 명세대로 돌린 첫 실행이 이 표다 — 같은 홀드아웃의 두 번째 개봉이다(첫 개봉은 개발 단계 모델). 그 뒤 같은 홀드아웃에서 seed 복제 · 시점 차단 · 다른 모델 둘(sol · luna)을 더 돌렸고(§4.4 · §4.7), 뒤의 실행은 이 표의 수를 고르는 데 쓰지 않았다.

평가 기준 — 이 순서로 본다 (제안서 §4)

1. 기각이 맞았나 — 기각 정밀도(기각한 것 중 실제로 실패한 약)
2. 맞는 것을 버렸나 — 성공한 약을 기각한 비율
3. 모르면 모른다고 하나 — 보류 비율 · Brier 를 널 모형(널 기저율)과 나란히. ECE 는 쓰지 않는다 — 균형 집합에서 널 모형의 ECE 가 0 이다
4. 모델 기억이 아닌가 — 모델 단독(B0)을 같은 쌍에 나란히 적고, 모델이 문헌 없이 «모름» 이라 한 문항에서 따로 잔다. AUROC 는 보조다(«보류» 를 0.5 로 뭉갬다)

지표	파이프라인 B5 · 전체 774쌍	모델 단독 B0 · 전체 774쌍	B5 · 모델이 «모름» 이라 한 445쌍 (사후)
기각 정밀도 (B0 는 «실패»)	99/105 = 94.3% [88.1–97.4]	122/126 = 96.8% [92.1–98.8]	38/41 = 92.7% [80.6–97.5]
↳ 근거로 한 기각만 (거부권 + 반박 우세)	66/70 = 94.3% [86.2–97.8]	—	15/16 = 93.8% [71.7–98.9]
↳ F0 기각 — 약 이름이 문헌에서 한 건도 안 잡힘	33/35 = 94.3% [81.4–98.4]	—	23/25 = 92.0% [75.0–97.8]
기각 재현율 (TN 중)	99/387 = 25.6% [21.5–30.2]	122/387 = 31.5% [27.1–36.3]	38/199 = 19.1% [14.2–25.1]
성공한 약을 버림 (TP 중)	6/387 = 1.6% [0.7–3.3]	4/387 = 1.0% [0.4–2.6]	3/246 = 1.2% [0.4–3.5]
«유망» 정밀도 (B0 는 «성공»)	126/167 = 75.4% [68.4–81.4]	137/203 = 67.5% [60.8–73.6]	40/48 = 83.3% [70.4–91.3]
보류 (B0 는 «모름»)	473/774 = 61.1% [57.6–64.5]	445/774 = 57.5% [54.0–60.9]	343/445 = 77.1% [73.0–80.7]
조건부	29/774	—	13/445
AUROC [95% CI]	0.712 [0.676–0.748]	0.698 [0.661–0.735]	0.670 [0.621–0.720] · B0 는 정의상 0.500
Brier (널 모형)	0.219 (0.250)	0.218 (0.250)	0.221 (0.247)

기각의 3분의 1은 근거를 읽지 않고 끊은 것이다. 기각 105건 중 35건은 약 이름이 문헌에서 한 건도 안 잡혀 F0 에서 끊었다(33건이 실패한 약) — 대부분 임상 등록부의 개입명이 개발 코드나 용량이 붙은 문자열이라서다. 근거로 기각한 70건만 보면 66건이 실패한 약이다(66/70 = 94.3% [86.2–97.8]). 헤드라인 정밀도는 F0 갈래가 만든 수가 아니다. 다만 F0 갈래는 자료원 차이(실패한 쪽에 개발 코드가 많다)를 그대로 싣는다.

전체 표본에서는 모델 기억이 더 잘 거른다. 모델 단독은 126건을 «실패» 로 버렸고 파이프라인은 105건을 기각했다. TN 에서 짝지어 보면 모델 단독만 버린 쌍 70 · 파이프라인만 버린 쌍 47 (McNemar $p = 0.042$ · 사후). AUROC 와 Brier 도 구별되지 않는다 — 이 표본에서 모델 단독에 대한 우위를 주장하지 않는다.

파이프라인의 뛴은 모델이 모르는 곳이다. 모델 단독이 «모름» 이라 답한 445쌍에서 모델 단독은 정의상 아무것도 거르지 않는다(0/199). 여기서 파이프라인은 41건을 기각했고 38건이 맞았다 — 이 부분 집합의 실패 비율은 199/445 = 44.7% 라, 무작위로 기각하면 정밀도가 그 근처다. 이 부분집합은 결과를 본 뒤 정했다(사후) — 다만 라벨이 아니라 모델의 출력만으로 고른다. 그 기각 41건 중 25건은 F0(약 이름 미검출)이고, 근거로 기각한 것은 16건(15건 맞음)이다 — 표본이 작아 방향으로만 읽는다. 문헌량 균형은 이 부분집합에서 재지 않았다(\$4.9 의 교란과 같은 모양일 수 있다).

모델 4개 — «모름» 문항의 파이프라인 AUROC: mini 0.615 · terra 0.670 · sol 0.692 · luna 0.642 · 95% CI 가 모두 겹친다(공통 [0.641, 0.667] · 사후). **이 표본으로는 모델 간 차이를 가르지 못한다.**

기각을 많이 하는 정도는 sol 에서 되풀이해 달랐다 — 표적 재시험(사전 지정 · 새 seed 셋): sol 만 기각 33 · luna 만 기각 7 · 합산 McNemar $p = 4.2e-05$ — 같은 27쌍을 seed 셋으로 합친 값이라 독립을 과대평가한다 (seed 별 $p = 0.013 \cdot 0.18 \cdot 0.0063$). 두 모델이 처음 같았던 27쌍에 한정한 결과이고, terra 와 luna 의 확인 검정은 갈리지 않았다.

seed 흔들림 — 같은 모델·다른 seed 판정 불일치 6.0% · 다른 모델 9.1% → 모델을 바꾸면 seed 를 바꿀 때보다 판정이 더 흔들린다 (추출 복제 · 사전 지정).

△ **한계** — ① TP(RepoDB 승인)는 모델이 학습 중 봤을 가능성이 크다 — 전체 표본의 모델 단독은 **암기 천장**이다 ② «모름» 부분집합은 **사후**다 ③ 라벨로 걸러 낸 «누출 제외» 부분집합은 모델 단독을 기계적으로 낮춘다(고확신 오답 37건이 남는다) — 비교에 쓰지 않는다.

4.2 보정 — 확률이 정직한가

Platt 보정(2모수 로지스틱[11])을 **개발 벤치마크(층 A)의 terra 점수로 적합해** 홀드아웃에 적용했다(층 A 와 겹치는 4쌍을 빼 770쌍). 보정은 단조변환이라 판정 · AUROC · 기각 정밀도는 바뀌지 않는다. 보정 모델은 그 모델의 점수에 맞춰야 하므로 개발 단계 모델로 맞춰던 보정 함수를 쓰지 않고 terra 로 다시 맞췄다(봉인 명세가 «재적합은 개발집합에서만» 을 허용한다).

Brier (낮을수록 좋다 · 770쌍)	원점수	Platt (층 A · terra 적합)
파이프라인 B5	0.220	0.212
모델 단독 B0	0.219	0.222
널 모형(늘 0.5)	0.250	—

짜지은 부트스트랩(2,000회) 구간으로 읽으면 —

- 보정은 파이프라인의 Brier 를 조금 낮춘다: -0.0077 [-0.0140, -0.0018]
- **파이프라인과 모델 단독은 구별되지 않는다** — 원점수끼리 +0.0010 [-0.0137, +0.0157] · 둘 다 보정해도 -0.0098 [-0.0251, +0.0046]
- 개발 단계 모델로 맞춘 보정 함수와도 구별되지 않는다: -0.0008 [-0.0020, +0.0004] — 모델에 맞춰 다시 맞추는 것이 원칙이지만 결과는 거의 같았다
- 모델 단독의 보정 효과는 **적합에 쓴 개발 실행에 따라 방향이 바뀐다** — 계산 전에 정해 둔 09-12 실행으로 맞추면 나빠지고(+0.0031 [+0.0013, +0.0050]), 같은 84쌍을 09-20 에 다시 돌린 실행으로 맞추면(사후 민감도) 나아진다 (-0.0029 [-0.0047, -0.0013]). 모델 단독 점수는 다섯 값뿐이고 같은 84쌍을 다시 돌리면 답이 바뀌어(두 실행 사이 15쌍) 84쌍으로 맞춘 보정 함수가 안정하지 않다. 파이프라인은 두 적합에서 0.212 로 같았고, 모델 단독과 구별되지 않는다는 결론도 같았다

수는 전부 `calibrate` 가 결과 파일에서 낸다 — 구간까지(재현 명령은 §9). **화면이 보여 주는 %는 보정 전 값이다** — 실시간 경로에는 보정을 붙이지 않았다. (전문: 보정결과_terra.md)

4.3 사전 기준 판정 — 42개를 하나도 빠지 않고

사전 기준 42개 — 통과 20 · 미달 14 · 판정 불가 8. 기준이 없는 절차 명세 3개와, 전제가 먼저 반증돼 실행하지 않은 명세 1개는 세지 않았다.

판정	기준 (대장 사전기준_대장.csv 의행을 줄여 적었다)
통과 20	생성 실험 — 효능 실패 비율의 신뢰구간 하한이 무작위보다 높다 · 라우터 병원체 분기 8/8 · 0/8 · 그래프 검색 두 방식 · 역발상(FAERS · SIDER) · 보정 두 기준(ECE 기준 — 뒤에 주장을 거뒀다) · 회의주의자가 홀드아웃에서 반박 근거를 늘린다(두 기준) · 라우터 그래프(사례 3건) · 병명 입구 두 기준 · 모델 교체 경로 불일치 4.1%(개발 단계 모델 짝) · 재시험 판정 일치(개발 6쌍) · 확률 변동폭 중앙값(개발 · 본선 재적용) · 모델 교체 시 검증 경로 불일치(luna · sol 각 1/98) · 네 모델 신뢰구간 겹침(약한 기준) · sol 의 초과 기각이 새 seed 에서 되풀이(33 대 7)
미달 14	홀드아웃 풀의 무작위 비율 38.8%(신뢰구간이 29%를 포함해야) · 시점 차단 비율(개발 모델 · 본선 모델 0.939 — 둘 다 ≤ 0.50 이어야) · 등록부 개입(판정이 갈린 쌍 0) · 그래프 검색 한 방식 · 역발상 순위를 성능으로 팔 수 있는가(보조 기준) · 용도 특허 신호 세 기준 · 회의주의자가 홀드아웃에서 근거 기반 기각을 늘린다(승인약 오기각 +5) · 병명 입구 두 기준(F0 통과율 · 150초) · 본선 재시험 판정 완전일치 72/84 · 추출 복제(모델 차이가 seed 흔들림보다 크다 — 예측은 «구별 안 됨»)
판정 불가 8	갈때기 실험($p = 0.077$ · 검정력 60%) · 회의주의자 28쌍 두 기준(검정력 2.5%) · 용도 특허 대조(검정력 31.3%) · 종 관문 16쌍 · 도킹 데모 · 전문 읽기 · 네 번째 모델 확인 검정($b \ 6 \cdot c \ 8 \cdot p = 0.79$)

셈법에 판단이 들어간다. 요약 문서들이 «미달» 로 적어 온 판정 불가 셋(갈때기 · 회의주의자 두 기준) 까지 미달로 세면 17, 같은 기준을 새 모델에 다시 댄 하나(본선 재시험 완전일치 72/84)를 빼면 13 이 된다. 그래서 한 수만 고르지 않고 대장 전체를 공개한다. **결과를 본 뒤 기준을 낮춘 기록은 없다** — 문턱을 고친 한 번(시점 차단 비율의 기준값)은 더 엄격해지는 쪽이었다. **봉인 뒤 본문을 고친 명세가 둘 있다** — 전문 읽기 명세는 봉인 직후 구성 이름만 고쳤고(결과 전), 모델 교체 명세는 봉인 다음 날 덧붙인 문단 때문에 1차 봉인 본문을 되살릴 수 없다. 둘 다 다시 봉인하며 두 해시를 남겼다.

4.4 시간 구조 — 반증 근거는 늦게 온다

같은 774쌍을 **시험 종료 1년 전까지의 문헌만** 보게 막고 다시 돌렸다(사전 지정). 본선 홀드아웃 명세의 **주지표**가 이것이다 — §4.1 의 정밀도 · 재현율은 부차 지표다.

TN 387	전 기간	1년 전 차단
총 기각	99/387 = 25.6%	93/387 = 24.0%
↳ F0 기각 (차단 시점 이전 문헌에서 약물이 안 잡힌다 · 전 기간의 33 에는 조 회 한도 초과가 잘못 들어간 1건 포함 · §2.5)	33	69
↳ 근거 기반 기각	66/387 = 17.1%	24/387 = 6.2%

사전 기준은 미달이다 — «차단 후 ÷ 전 기간 ≤ 0.50 » 이어야 했는데 0.939 다. 분해하면 이유가 보인다 — 근거가 «있어서» 한 기각이, 근거가 «없어서» 한 기각으로 대체됐다. 근거 기반 기각만 세면 17.1% → 6.2%로 무너진다. 시간 구조는 있었고, 총량으로 세는 지표가 그것을 감쌌다. 다만 사전에 «기각 재현율»이라고만 적었으므로 **미달은 미달로 보고하고**, 분해는 결과를 본 뒤의 분석으로 적는다.

부수 효과 — 시점 차단은 누출 차단을 겸한다. 라벨이 된 시험의 결과 논문은 종료 **이후**에 나오므로, 같은 홀드아웃의 첫 개봉(개발 단계 모델)에서 1년 차단 실행의 누출은 0건이었다.

4.5 생성 — 무엇이 나오는가

사전명세 실험 — 질환 12개 × 프롬프트 2종 × 요청 20개 → 후보 340건(개발 단계 모델 gpt-5.4-mini). «확실한 것만» (strict)과 «확신 없어도 좋다»(loose)를 **둘 다** 돌렸다 — 프롬프트 한 줄이 결론을 정하지 않게 하려고.

	strict	loose
요청 대비 생성 충족	119/240 = 49.6%	221/240 = 92.1%
이미 그 병의 승인약 (프롬프트가 명시적으로 금지)	28/119 = 23.5%	52/221 = 23.5%
이미 효능 실패로 중단된 약	3/119 = 2.5%	6/221 = 2.7%

사전 기준(효능 실패 비율의 95% 신뢰구간 하한 > 무작위 기준선 0.36%)은 **통과했다** — 우연의 약 7배다. 그런데 **우리 예측(5–15%)은 빗나갔다**. 크게 나온 것은 다른 곳이었다 — **넷에 하나가 이미 그 병의 승인약**이었고, 질환별로 방향이 읽힌다(고콜레스테롤혈증 13/20 = 65% · 류마티스 관절염 10/21 = 48% · 궤양성 대장염 14/35 = 40% · 유방암 2/32 = 6% · 조현병 0/35 = 0%). 표준치료가 굳어 있을수록 그것을 재창출 후보로 내민다. 신중하라고 시키면 **개수는 절반으로 줄었지만 승인약 재탕 비율은 같았다** — 적어도 이 지표에서 생성기의 자제는 수량 자제였다(효능 실패 비교는 검정력 3%라 모른다).

확장 실행 — 질환명 37개(효능 실패 · 승인이 각 3건 이상인 것 전부 · 동의어가 섞여 있다) · 같은 프롬프트 2종 → 후보 1,074건(개발 단계 모델).

생성기가 낸 것	비율
이미 그 병의 승인약	17% [15–19]
이미 효능 실패로 중단	2% [2–3] (25건)
사유 불명으로 중단	10%
우리 자료에 없음 (신규 후보라는 뜻이 아니다)	71%

가장 강한 관찰 — 생성기는 실패를 말하지 않았다. 사전명세 실험에서 효능 실패로 잡힌 9건의 근거 문장을 전부 읽었다. 실패 · 무효 · 중단을 언급한 것은 **0건**이다(9건이라 95% 신뢰구간 상한은 30% · 사후 감사에서 9건 중 2건은 등록 미달이 효능 실패로 잘못 분류된 것이었다).

후보	생성기가 적지 않은 것
pioglitazone / 알츠하이머병	TOMMORROW · n=3,494 · «Lack of efficacy»
azithromycin / 천식	AZ-SWED · n=840 · NHLBI 가 무익(futility)으로 중단 — 대상은 미취학 아동의 급성 중증 천명이다(성인 지속성 천식의 AMAZES 는 양성)
losartan / COVID-19	NCT04606563 · n=341 · 자료감시위원회 무익 판정
camostat / COVID-19	NCT04625114 · n=108 · 중간분석 무효

지어낸 문장은 없었다 — 전부 사실이고 **한쪽만 담았다**. 9건 중 6건은 스스로 «임상 근거 있음» 이라 표시했는데, 중단된 그 시험은 말하지 않았다. 다만 대상군이 다른 시험도 있어(AZ-SWED · TOMMORROW 는 예방 시험) «실패가 확인됐다» 가 아니라 «중단된 시험을 말하지 않았다» 까지로 읽는다. 340건 전체에서도 근거에 부정적 표현이 들어간 것은 $23/340 = 6.8\%$ 뿐이다. 반증 깔때기가 필요한 이유다. 실패를 먼저 말하라고 시키는 프롬프트는 시험하지 않았다.

4.6 인용 검증 — «생성된 정보가 실제 데이터와 일치하는가»

본선 홀드아웃 실행의 인용 **전부**를 켜다(LLM 0회 · 판정할 때 기록된 대조 결과를 다시 읽었다 · 본선보조분석_0926.md).

	실측 [95% CI]	분모
충실도 — 인용 문장이 초록 원문에 실재	2128/2129 = 99.95% [99.73–99.99]	검사까지 간 인용
관련성 — LLM 이 낸 인용 중 쓸 수 있던 것	2129/6657 = 32.0% [30.9–33.1]	LLM 이 낸 인용 전부
초록에 없는 문장 (지어낸)	1건	—

분모를 둘로 나눈 것이 요점이다. 검사 전에 빠진 4,528건(무관 3,927 · 초록 없음 306 · 라벨 출처 192 · 기타 92 · 철회 11)을 «불충실» 로 세면 틀리고, 분모가 줄었다는 사실을 감추면 충실도가 부풀려진다.

그리고 문자열 대조로는 안 걸리는 층이 더 크다.

층	걸림 / 기회	비율
연구 유형 충돌 — LLM 이 말한 유형이 PubMed 와 다르다	844/6056	13.9%
결과를 진술하지 않는 문장 («측정 방법» · «환자 배정»)	374/2128	17.6%
그 약을 지목하지 않는 간접 근거	270/2128	12.7%
같은 시험의 중복	40/261	15.3%

지어낸 것은 원문 대조까지 간 2,129건 중 1건이고, 관계가 틀린 것은 열에 한두 건이다. 이 시스템이 존재하는 이유가 그 층이다. 이 수치는 RAGAS 가 아니고(LLM 심판을 쓰지 않는다), 원문 대조 자체는 우리 발명도 아니다 — CiteCheck 가 원문 일치에 의미 유사도까지 더해 더 넓게 본다[9]. 사전 문턱이 없는 서술 결과다.

4.7 판정은 얼마나 단단한가

물음	실측	읽기
근거 하나만 빼면 뒤집히나 — 판정 취약성[12]	기각 105건 중 39건이 취약도 1 · TN 기각 38/99 · TP 기각 1/6	판정만 보지 말고 근거 목록을 같이 봐야 한다
같은 모델 · 같은 seed 로 8일 뒤 다시	84쌍 중 판정 완전일치 72/84 (사전 기준 미달) · 확률 변동폭 중앙값 0.0%p(통과) · 평균 3.8%p · 최대 49%p	대부분 그대로지만 경계 사례가 움직인다
seed 만 바꿀 때 와 모델을 바꿀 때	판정 불일치 6.0% 대 9.1% · 차 +3.1%p [+2.1, +4.1] (사전 지정 · 우리 예측은 «구별 안 됨» 이었고 빗나갔다)	모델을 바꾸는 효과가 더 크다
두 모델(sol · luna)이 갈린 27 쌍을 새 seed 셋으로	sol 만 기각 33 · luna 만 기각 7 · 사전 지정 합산 McNemar $p = 4.2e-05$ — 같은 27쌍을 seed 셋으로 합친 값이라 독립을 과대평가한다(seed 별 $p = 0.013 \cdot 0.18 \cdot 0.006$)	sol 의 초과 기각이 되풀이됐다. terra 와 luna 의 확인 검정은 갈리지 않았다($p = 0.79 \cdot$ 검정력 0.45)
가장 강하게 기각한 100개의 정밀도	모델 단독 0.972 · 파이프라인 0.950 (모델 단독 점수는 다섯 값뿐이라 동점은 무작위 200회 평균)	모델 단독이 앞선다 — «외워서 맞힌다» 는 가설이고 재지 않았다

(전문: 본선보조분석_0926.md · 재현성결과_0920.md · 홀드아웃_본선모델_결과.md)

4.8 전향 봉인 예측 — 결과를 모르는 채로 봉인했다

진행 중 임상 60건(1차 완료 후 11~13개월 · 결과 미게시)과 무작위 음성대조 20쌍을 예측하고(개발 단계 모델 · 구성 B5), 그 해시를 제3자 타임스탬프로 등록했다. **결과가 나오기 전에 봉인했으므로 우리가 결과를 보고 고칠 수 없는 유일한 숫자다.** 결과는 2027년까지 나온다.

	유망	조건부	보류	기각
진행 중 60건	22	0	27	11
무작위 음성대조 20쌍	0	0	17	3

결과를 안 기다려도 나온 것 하나 — **무작위 쌍에 «유망» 을 준 것이 하나도 없다**(진행 중 22/60 = 37% 대 음성대조 0/20 · $p < 0.001$). 문헌량을 맞춰도 68% 대 0%($n = 31$ 대 6 · $p = 0.003$)로 남는다. 다만 맞춘 뒤 대조군이 6건뿐이라 0% 가 아니라 «39% 이하» 로 읽어야 한다.

그리고 제안서의 예측은 빗나갔다. 제안서는 음성대조를 «낮은 신뢰도로 기각» 할 것이라 썼는데, 시스템은 대부분 기각하지 않고 **기권했다**(17/20 = 85% 보류 · 기각 3). 근거가 없으면 판단하지 않는 것이 설계이고, 틀린 것은 제안서의 문장이다.

4.9 유의한 값을 하나 버렸다 — 교란

같은 홀드아웃의 첫 개봉(774쌍 · 개발 단계 모델)에서, 모델 단독이 «모름» 이라 한 문항만 모아 파이 프라인의 정확도를 재니 다수클래스보다 유의하게 높았다. 사전에 지정해 둔 **문헌량 균형 부분집합**에서 다시 재니 사라졌다.

	미지 영역 정확도	다수클래스	p
전수 (TN-TP 짝 387)	75% (101/135)	59%	< 0.001
균형 짝 56 (사전 지정)	65% (15/23)	61%	1.000
개발 벤치마크 (짝 42 · 문헌량이 맞춰진 원본)	65% (13/20)	57%	0.509

문헌량 교란과 일치한다(§8 한계 3). 균형을 맞추면 65%로 내려가 다수클래스와 구별되지 않고, 그 65%가 원본 벤치마크와 같다 — 다만 균형 짝 56 가운데 정확도를 잰 문항은 23건이라 구간이 넓어(약 45–81%) 교란이라고 단정하지는 못한다. 같은 모양의 제출 모델 «모름» 부분집합 (§4.1)은 이 균형 검사를 하지 않았다. 여기서 멈췄으면 «미지 영역에서 유의하게 우수하다»고 보고했을 것이다. **사전명세가 막은 것은 실수가 아니라 자기기만이다.**

4.10 «모른다»와 «차이 없다»는 다르다 — 깔때기 실험

생성된 후보를 깔때기가 실제로 거르는지 봉인하고 잰다(개발 단계 모델).

TN(효능 실패) 근거 기반 기각 $6/14 = 42.9\%$ [21.4-67.4]
TP(승인) 근거 기반 기각 $1/14 = 7.1\%$ [1.3-31.5]
Fisher $p = 0.077$ · 검정력 60% · 필요 표본 22쌍(실행 전에 계산) · 실제 14쌍

방향은 6배 차이인데 유의하지 않다. 필요 표본을 **실행 전에** 계산해 두었고, 14쌍밖에 못 모았다. 이 실험의 결론은 «**효과 없음**»이 아니라 «**측정 불가**»다 — 판정 불가로 썼고, «차이 없다»로 쓰지 않았다.

4.11 발굴 보조 — 역발상 · 그래프 · 특허

	무엇을 잰나	결과
역발상 발굴 (FAERS 부작용 신호)	상위 후보가 무작위보다 문헌이 있는 후보를 더 내는가	F0 통과 82.3% 대 무작위 64.0% · Fisher $p = 0.006$ — 통과
역발상 발굴 (SIDER)	같은 기준 · 순위가 부작용 개수만 반영하는가(보조)	기준 통과(경계) · 보조 기준 미달 → 순위를 성능으로 내세우지 않는다
그래프 검색 (DRKG)	세 방식이 차수 대조군을 이기는가	둘 통과 · 하나 미달
특허 (SureChEMBL 로컬 색인)	관련 특허 검색 · 용도 특허 신호	검색까지 — 신호는 기준 미달(공동청구 72.7% · 기준 $\leq 60\%$)이라 판정에 쓰지 않는다

역발상은 «**정보가 있는 후보를 무작위보다 많이 낸다**»까지만 잰다. 그 후보가 맞는지는 재지 않았다.

5. 우리 도구를 우리가 반증한 기록 — 결함 387건

측정 · 문서 · 절차에서 스스로 찾은 결함 387건을 전부 공개한다(Bio-ReRoute_발견정리.md · 건마다 코드 위치와 결과). 유형 여덟으로 묶으면 반복이 보인다.

유형	건 수	대표 사례
검증 환경 ≠ 실행 환경	36	모의로만 → 첫 실패율이 0건 · 안 써 본 의존성이 다섯 달 전에 죽어 있었다 · 모의가 실제 출력보다 좁아 시험이 녹색인 채 실패를 감쌌다
캐시는 최적화가 아니라 자료원	16	일시 장애 380건이 캐시에 박혀 누출 차단이 88%에서 안 걸렸다 · 읽기 실패를 «빈 캐시» 로 승격시켜 33MB 를 스스로 지웠다
규칙·검정을 잘못 골랐다	10	상수 기준선에 Fisher · 한 후보에 무게 체계가 둘 → 유망 90%
같은 실수가 파일을 옮겨 재발	29	숫자 표기 드리프트 세 번 · 일괄 치환 사고 일곱 번 · 새 파일이 <code>cache.load()</code> 를 안 불렀다 · 틀린 값이 발표자료로 베껴졌다
안내문은 방어가 아니다	47	검토지에 답을 넣고 “보지 마라” · 검증절차를 만든 날 밤에 그 절차를 건너뛸
재는 것 ≠ 잰다고 말하는 것	149	정답표의 37%가 다른 실패 모드 · 우리 작업 기간을 실제의 3배로 적었다 — 99곳 · 「기각 재현율」의 분자에 오답이 섞인 채 7주
만든 것을 눈으로 안 봤다	53	표가 깨지고 마크다운이 노출됐다 — 5.9 GB 를 받아 색인하고도 그 파일을 안 읽었다 · 화면 클릭 한 번이 30초인 걸 아무도 안 잰다
고친 자리의 이웃을 안 본다	47	질의를 고치니 그 문구로 분기하던 곳이 죽고, 라벨을 늘리니 쓰는 쪽이 몰랐다 — 허브 편향을 고친 것은 대조군보다 나빴다
합	387	대장(Bio-ReRoute_발견정리.md)의 행 수와 같다 — 회귀 시험 65번이 지킨다

(이 표는 발표 «우리 도구를 우리가 반증한 기록» 장의 막대와 같은 목록에서 나온다 — `py -m bioreroute.bench.defecttypes`)

여덟 유형이 같은 결말이다 — «조심하자» 로는 안 막혔고, 코드가 막으니 막혔다. 그래서 규약을 하나씩 구조로 바꿨다.

되풀이된 실수	규약이었던 것	구조로 바꾼 것
문서마다 수치가 갈라진다	«고칠 때 다 찾아 고쳐라»	문서 감사기가 결함 수 · 시험 수 · 판 번호 · 사전 기준 집계를 문서 전부에서 대조하고, 정본과 다르면 고치는 명령을 찍는다
손으로 옮긴 수가 틀린다	«코드에서 복사해라»	이 보고서의 §4.1 · 결함 유형 표 · 발표 성능 장을 결과 파일에서 직접 생성한다
조회 실패를 0건으로 센다	«실패를 조심해라»	실패한 쌍은 분모에서 빼고, 전부 실패하면 판단을 거부한다
시험이 실제 자료를 덮어쓴다	«시험은 임시 폴더에서»	시험 중 저장소 쓰기를 막는 감시기 — 쓰면 실패로 올린다
저장이 끊기면 반쪽 파일이 남는다	«조심해서 저장»	임시 파일에 쓰고 원자적으로 바꾼다
배포했다고 믿는다	«올렸는지 확인해라»	배포본을 내용 해시로 대조하는 확인 도구

가장 위험했던 것은 **우리에게 유리한 고장**이었다. 한 도구가 조회 실패(네트워크 403)를 0건으로 합산해 «반증 근거의 부재는 구조적이다»라는 결론을 출력했다 — 논지를 지지하는 방향이었고, **숫자가 너무 좋아서** 의심한 것이 유일한 방어였다. 그것은 방어가 아니다. 두 번째로 아팠던 것은 캐시에 박힌 일시 장애가 누출 차단을 무력화한 것이다 — 실측하니 색인된 80건 중 6건이 라벨 출처 논문을 읽고 있었다. 주지표 판정은 바뀌지 않았지만 **그 여섯은 예측이 아니라 답안지 읽기**였고(6건 모두 기각 · 5건은 그 논문이 결정적), 이름과 가중치까지 적었다.

고치지 않기로 한 결함도 남긴다. 메타분석에는 시험 번호가 없어 중복 제거가 걸리지 않는다 — 같은 시험을 묶은 메타분석이 서로, 그리고 원 시험과 따로 세어진다. 데모의 플루복사민 / 코로나19 는 지지 쪽 확증 근거 무게의 76%(4.92/6.45)가 메타분석 셋에서 오고, 그중 Cochrane 2022 가 묶은 두 시험(미국 152명 · 브라질 1,497명) 가운데 미국 시험(JAMA 2020)은 따로 RCT 로도 세어진다. 이 쌍의 판정 «조건부» 는 셋을 하나로 묶어도 그대로다(지지·반박 무게비 0.57 → 0.83 · 문턱 0.5). 가중 규칙을 바꾸면 지금까지 쟀 모든 수치가 다른 시스템의 수치가 되므로 고치지 않고, 근거 카드에서 그 이유가 그대로 보이게 둔다. 감사 추적이 본체라는 주장의 가장 좋은 증명은 **자기 오류를 보이는 것**이다.

6. 반증 조건 — 이 관찰이 나오면 우리 논지가 틀렸다

중심 명제: «**값싼 반증 관문을 앞에 두면, 그럴듯하지만 틀린 후보를 더 정확하게 거르고 더 정직한 확률을 낸다.**»

#	이 관찰이 나오면 틀렸다	본선 결과
F1	관문을 전부 꺼도(모델 단독) 특이도가 같거나 낮다	전체 774쌍에서 실현 — 모델 단독이 더 많이, 더 정확하게 거른다(기각 재현율 31.5% 대 25.6% · McNemar $p = 0.042$ · 사후). 모델이 «모름» 이라 답한 445쌍에서는 아니다 (사후) — 정의상 모델 단독은 거르지 않고, 파이프라인은 TN 199 중 38 을 걸렀다(기각 41건 중 38건 적중 · 이 부분집합의 실패 비율 44.7%)
F2	보정이 관문으로 좋아지지 않는다	실현 — Brier 가 모델 단독과 구별되지 않는다(원점수 · 보정 후 모두). 나빠진 것도 아니다
F3	반증 근거가 애초에 없다	부분 실현 — 종료 시험 전체에서는 2.3%. 개발 단계 모델이 제안한 후보 14쌍으로 좁히면 무작위 시험이 있는 쌍이 79%(결과 방향 무관 · 사후)
F4	생성기가 이미 실패를 알고 피한다	실현 안 됨 — 효능 실패 후보 9건 중 실패를 언급한 것 0건(개발 단계 모델 · 9건 중 2건은 사후 감사에서 등록 미달로 밝혀졌다)
F5	걸러낸 후보가 사후에 유효로 밝혀진다	부분 실현 — 기각 105건 중 6건이 승인약(5.7%) · 그중 근거 하나로 뒤집히는 것은 1건이고, 2건은 옛 약 이름이 PubMed 에 없어 F0 로 기각됐다

읽기 — 다섯 중 둘이 실현, 둘이 부분 실현, 하나(F4)는 실현되지 않았다. 논지는 좁혀진다 — **모델이 이미 아는 후보에서는 관문이 모델 기억을 이기지 못하고, 모델이 모르는 후보에서 값을 한다**(사후 부분집합에서 본 것이다 · 일반 질의응답에서 이미 보고된 모양이다[23]). 생성형 모델이 커질수록 «아는 영역» 은 넓어지므로, 이 시스템의 쓸모는 **기억 밖의 후보를 근거와 함께 거르는 것과 왜 그렇게 판정했는지 남기는 것으로** 모인다.

7. 선행연구 — 무엇이 우리 몫인가

열 번 찾았고, 찾을 때마다 주장이 줄었다.

우리가 주장하려던 것	선행연구	판단
«반증이 병목»이라는 문제 정의	Maziarz & Stencel 2022 — 사례 약물도 HCQ[4]	철회 — 우리는 그 처방을 절차로 만들었다
도킹이 대개 맞지 않는다	세포 실험에서 감염을 줄인 약 77개 중 76개가 SARS-CoV-2 가 결합하는 단백질에 안 붙는다[5]	철회 — 우리 몫은 후보별 자동 판단과 기록
생성기-회의주의자 토론 구조	RareAgent[7]	철회
역사적 실패를 음성으로 쓰는 벤치마크	실패를 단계별로 등급화(hard · medium negative)한 선행 벤치마크	철회 — 그쪽이 더 정교하다
AUROC 를 그대로 믿지 않는다 · 코드 공개	Guney 2017 — 약물을 분리하면 AUC 84.1% → 65.6%[8]	축소
인용을 원문 문자열로 대조	CiteCheck[9] · CiteGuard[18]	철회 — CiteCheck 가 더 넓다
활성부위 pLDDT 를 도킹 기준으로	결합 부위 pLDDT 가 70 이상인데 도킹 성능이 나쁜 사례[10]	필요조건으로만 쓴다
저자가 적은 한계로 근거 무게를 내린다(전문 읽기 F)	GRADE — 연구의 한계가 심각할수록 근거 수준을 내린다[20]	철회 — 우리 것은 GRADE 의 조잡한 자동화판이다
사전등록 · 봉인 방법론	LLM 평가 분야의 사전등록(OSF 등)[21][22]	도메인 이전이지 발명이 아니다 — 그쪽은 제3자 저장소에 등록했다
모델이 모르는 후보에서 파이프라인이 값을 한다 (\$4.1 · 사후)	덜 유명한 개체에서는 검색으로 보강한 모델이 훨씬 큰 모델을 이기고, 유명한 개체에서는 보강 없는 모델도 경쟁력이 있다[23]	도메인 사례이지 새 발견이 아니다 — 모델이 «모름» 일 때만 검색하는 구성도 그쪽 제안이다
미리 정한 기준으로 재고 미달을 공개한 것	찾지 못했다	남는다 — «못 찾았다» 는 «없다» 가 아니다
스스로 찾은 결합 387건 공개	찾지 못했다	남는다
후보마다 검증 경로를 정하고 안 돌린 이유를 판정 기록에 남기는 구현	구성 요소는 있다[5][7]	구현과 그 실측(라우터 8/8 · 0/8 · 도킹 9/9 불가)이 우리 몫이다

Guney 의 결과는 우리 AUROC 를 읽는 데도 쓴다 — 약물을 분리해 평가하면 AUC 가 65.6%로 내려간다[8]. 과제와 자료가 달라 직접 비교할 수는 없지만, «0.7 대는 낮다» 는 인상은 분할 방식이 만든 기대치일 수 있다.

8. 한계

1. **모델 단독에 대한 우위가 없다.** 전체 표본에서 모델 단독이 더 거르고(\$4.1), 보정도 구별되지 않는다(\$4.2). 파이프라인의 뒤편 모델이 모르는 후보(사후 · 그 기각 41건 중 근거로 한 것은 16건)와 근거 추적이다
2. **정답표 양쪽이 깨끗하지 않다.** TP 는 RepoDB — 모델이 학습 중 봤을 가능성이 크다(암기 천장). 개발 벤치마크 TN 49건 중 37%는 효능 실패가 아니었고, 봉인 홀드아웃 TN 은 실패 모드별로 감사하지 않았다(\$3.2) — 같은 적응증의 승인약이 비교군 · 병용으로 든 시험(예: tocilizumab / COVID-19 · docetaxel / 비소세포폐암)도 TN 에 섞여 있다. 이 잡음은 양쪽으로 작용한다(맞은 기각으로 셀 수도, 틀린 «유망» 으로 셀 수도 있다). 실패 모드별 라벨링은 다음 명세에서 사전에 한다
3. **문헌량 교란.** 홀드아웃 TN 은 최근 종료된 시험이라 문헌이 적고(중앙값 5건) TP 는 많다(28건) — 짝지은 쌍의 문헌량 부호평균(TP-TN) +0.471 은 허용치(± 0.15)의 3배다(사전명세.md). 다음 홀드아웃은 TN · TP 를 같은 모집단에서 뽑아야 한다
4. **검정력이 모자란 결과가 많다.** 그것을 «차이 없다» 가 아니라 «모른다» 로 적었다(판정 불가 8). 여기 적은 검정력은 대부분 관측 효과로 계산한 사후 값이라 p 와 같은 정보다 — «모른다» 의 근거는 넓은 구간이다. 그리고 p 값이 많다 — 사전 지정 주지표를 빼면 다중비교를 보정하지 않은 탐색적 값이다
5. **재현성.** 같은 seed 로 8일 뒤 다시 돌려도(캐시를 비켜 그사이의 문헌 변화도 섞였다) 84쌍 중 12쌍의 판정이 바뀌었다. 모델을 바꾸면 기각을 많이 하는 정도가 달라질 수 있다(sol · \$4.7). 데모 병명 경로도 두 번 돌리니 10개 중 2개가 달랐다
6. **사람 채점자가 한 명이다.** 팩트체커와 사람의 방향 일치 75%(18/24 · $\kappa = 0.596$ · 개발 단계)는 사람 채점 자체의 신뢰도를 모른다
7. **79%(제안 후보 중 무작위 독립 시험이 있는 쌍)는 사후 대조다**(\$1.2)
8. **화면의 %는 보정 전 값이다**
9. **S1 구조 게이트는 약한 대리물이다** — 활성부위 주석이 없으면 단백질 전체 pLDDT 평균을 쓴다. pLDDT 는 결합력이 아니다
10. **자율 재계획이 없다.** 계획은 라우터의 경로 선택이 전부다
11. **안전 게이트는 이름 대조다.** 작성한 우회는 못 막는다. 이 도구는 **의학적 조언이 아니다**(화면과 산출물에 표기)
12. **«먼저 적었다» 의 증거 강도가 명세마다 다르다**(\$3.4) — 본선 홀드아웃 명세는 로컬 봉인 파일 뿐이다
13. **홀드아웃을 여러 번 썼다.** 본선 헤드라인은 같은 774쌍의 두 번째 개봉(제출 모델 첫 실행)이고, 우리는 첫 개봉 결과를 본 뒤였다. 그 뒤 seed 복제 · 시점 차단 · 다른 모델 둘(sol · luna)도 같은 쌍을 썼다 — 봉인 명세가 적은 «발표 표는 첫 개봉과 두 줄로» · «세 번째 개봉은 없다» 는 지키지 못했다(첫 개봉 값은 홀드아웃결과.md 에 있다). 이 자료로 모델 · 문턱 · 프롬프트를 고르지 않았다
14. **«우리 자료에 없음» 은 신규 후보가 아니다.** 발견 지표(Hit@k 등)는 학습 자료의 회상이라 주장하지 않는다
15. **데모 구성은 벤치마크하지 않았다.** 시연은 평가 구성(B5)에 구조 · 전문 읽기를 더한 B5SF 로 돈다 — 전문 읽기를 따로 켜 실험은 판정 불가였다(\$4.3)

16. **개발성 관문(S2)이 후보의 30%에서 돌지 못했고, 그 결손이 한쪽으로 쏠렸다.** 제출 실행의 판정 기록을 다시 세어 보니 S2 가 774건 중 **231건(29.8%)**에서 SMILES 를 못 받아 ERROR 로 남아 있다(PubChem 이 «그 이름 없음» 으로 답한 것 229 · 형식 오류 2). 이름으로 보면 셋이 섞여 있다 — 항체 · 혈액제제 같은 **저분자가 아닌 것**, 개발 코드 · 용량이나 제형이 붙은 이름 · 복합제처럼 **저분자인데 이름을 못 푼 것**, 시술 같은 **약이 아닌 개입**. 쓸림이 크다 — **TN 387 중 205(53.0%) · TP 387 중 26(6.7%)**. §4.1 의 F0 갈래(실패한 쪽에 개발 코드가 많다)와 **같은 비대칭을 다른 자료원에서 다시 본 것이다**. S1 · S2 는 판정에 들어가지 않으므로(`core/scoring.py` 의 판정 함수는 F0 · 거부권 · 근거만 읽는다) §4.1 의 수치는 이 결손에 영향받지 않는다. 그래도 둘이 남는다 — **§2.1 의 S2 행은 조건 없이 적혀 있어 모든 후보에 도는 것처럼 읽히지만 실제로는 이름이 풀린 후보에만 돌았고**, 기록이 «대상 아님» · «이름을 못 푼» · «조회 실패» 를 ERROR 하나로 뭉쳤다. 제출 직전에 코드를 고치지 않았다: 기록 문구를 바꾸면 동결된 실행과 대조가 어긋난다
17. **문헌과 라벨의 자료원이 각각 하나이고 영어다.** 평가 구성의 문헌은 PubMed 초록이고(시연은 PMC 전문의 한계 절을 더한다) 실패 라벨은 ClinicalTrials.gov 뿐이다 — 다른 나라 등록부 · 비영어 문헌 · 학회 초록 · 특허 문헌은 보지 않는다. 그래서 **«문헌 근거 없음» 은 «이 자료원에 없음» 이다**
18. **제3자 독립 검증이 없다.** 1인 팀이 코드 · 측정 · 문서 · 결함 대장을 다 만들었고, 밖에서 결과를 복제하거나 코드를 감사한 적이 없다. 봉인 해시의 제3자 타임스탬프는 **«그때 적었다» 의 증거이지 «맞다» 의 증거가 아니다**
19. **«효능 실패로 중단» 은 «가설이 틀렸다» 와 같지 않다.** 용량 · 환자군 · 설계 · 검정력 때문에 멈춘 시험도 라벨상 TN 이고, 같은 약-질환이 다른 조건에서 다시 성립할 수 있다. 우리가 쟀 것은 **그 라벨을 걸러내는 능력이다** — 평가 측 자체가 그만큼 좁다(§3.2 가 «어떤 이유로든 중단된 시험» 이라 적은 것의 다음 층이다)

이 열아홉을 넷으로 가르다. 「어려운 문제라 남았다」와 「우리가 안 했다」를 섞어 적으면 한계 목록이 방패가 된다 —

성격	어느 것	무엇이 필요한가
고치는 법이 분명하고 자원만 든다	2 · 3 · 4 · 6 · 9 · 15 · 16 · 17 · 18	실패 모드별 사전 라벨링 · TN 과 TP 를 같은 모집단에서 뽑은 새 홀드아웃 · 더 큰 표본 · 채점자 둘 이상 · 포켓 예측기 · 데모 구성으로 774쌍 한 실행(약 520만 토큰) · 이름 해소를 한 겹 더 두고 «대상 아님» 을 «조회 실패» 와 가르기 · 등록부와 언어를 더하기 · 밖의 감사자 한 명
우리가 고른 자리	8 · 10 · 11	바꾸려면 설계 결정을 바꿔야 한다. 8 은 코드로는 한 줄이고, 안 붙인 이유를 «안한 것» 표에 적었다
되돌릴 수 없다	12 · 13	이미 일어난 봉인과 개봉이다. 다음 홀드아웃을 새로 동결하는 것 말고는 방법이 없다
자료와 방법의 성질로 남는다	1 · 5 · 7 · 14 · 19	정답표가 학습 자료와 겹치는 한, LLM 이 같은 입력에 다른 답을 내는 한, 라벨이 «중단» 이고 우리가 알고 싶은 것이 «틀린 가설» 인 한 남는다. 줄일 수는 있고 없앨 수는 없다

«원리상 불가능하다» 고 적은 항목은 하나도 없다. 열아홉 중 아홉은 다음 판에서 자료원으로 닫히는 것이고, 어떻게 닫는지를 위 오른쪽 칸에 적어 둔다.

안 한 것 — 그리고 그 이유

성격을 같이 적는다. 아래 아홉 중 **원리상 못 하는 것은 없다** — 넷은 우리가 고른 것, 둘은 자료와 시간이 막은 것, 하나는 사람이 없어서, 하나는 법률 판단이라 범위 밖이고, 하나는 **할 수 있었는데 안 했다**. 마지막 하나를 «못 한다» 로 적지 않는 것이 이 표의 요점이다.

항목	상태	이유	성격
도킹(제안서의 S3 관문)	하지 않았다	제안서가 한 곳(§3.3)에서는 로드맵, 다른 곳(§2.4 · §3.1)에서는 핵심 검증이라 적었다 — 핵심 쪽을 따라 열었고, 라우터가 구조 경로로 보낸 8건과 maraviroc 까지 자료가 9/9 도킹 불가로 답했다 (§2.3)	자료가 막았다 · 규칙은 고치지 않았다 — 결과를 보고 완화하면 그게 조정이다. 포켓 예측기를 쓰면 maraviroc 한 건은 열렸을 수 있다 (아래 행)
전문가 피드백 루프(HITL)	코드만 있다 · 측정과 시연에서 꿈	평가할 전문가가 없다. 반쯤 만든 기능을 수치 없이 내세우지 않는다	사람이 없어서 — 기능은 있다
특허 자유실시 (FTO) 판단	관련 특허 검색까지	자유실시는 법률 판단이다. 용도 특허 신호는 사전 기준 미달이라 판정에 쓰지 않는다	범위 밖 — 검색은 했고 판단은 변호사 몫이다
포켓 예측 (fpocket 등)	하지 않았다	UniProt 활성부위 주석을 쓴다. 주석이 없으면 전체 평균(약한 대리물)	할 수 있었는데 안 했다 — 무료 · GPU 불필요다. 붙이면 한계 9 가 약해지고 CCR5 상자도 정해진다. 판정 경로를 늦게 건드리지 않기로 해 다음으로 넘겼다
개발성 회귀 모델(LDTS)	하지 않았다	학습 라벨(ChEMBL 개발 단계)이 효능을 섞어 재므로, 학습하면 개발성 점수가 효능을 재게 된다	우리가 고른 것 — 지표를 오염시키지 않으려고
RAGAS · LLM 심판	하지 않았다	LLM 이 LLM 을 채점하지 않는다 — 원문 문자열 · 수치 대조로 잰다(§4.6)	우리가 고른 것
에이전트 프레임워크 (LangGraph 등)	의도적으로 안 썼다	관문을 커고 끄는 반복문 하나가 제거 실험을 만든다	우리가 고른 것
실시간 화면에 보정 붙이기	하지 않았다	붙이면 데모 스냅샷과 발표의 %가 다 바뀌고, 제출 직전에 판정 경로를 건드리게 된다(보정결과_terra.md)	우리가 고른 것 — 기술로는 한 줄 이다. 그래서 한계 8 로 적어 둔다
진행 중 임상 예측의 채점	기다린다	결과가 2027년까지 나온다(§4.8)	시간이 막았다

9. 재현

```
py -m bioreroute.netcheck # 외부 조화가 살아 있는가 (LLM 0회)
py -m bioreroute.run --pair "약물 / 질환" # 임의 가설을 즉석 검증 (API 키 필요)
py app.py # 웹 화면 (로컬)
py -m bioreroute.bench.perfcard # 4.1 성능 표 (LLM 0회)
py -m bioreroute.bench.calibrate --fit 케적_0912.json --eval 홀드아웃_본선모델.json --compare-fit bench_r
py -m bioreroute.bench.calibrate --fit 재현성_0920b.json --eval 홀드아웃_본선모델.json # 4.2 민감도(사
py -m bioreroute.bench.prereg # 4.3 사전 기준 대장 집계
py -m bioreroute.bench.fairful --state 상태_홀드본선_B5.json # 4.6 인용
py -m bioreroute.bench.fragility --state 상태_홀드본선_B5.json # 4.7 취약성
py -m bioreroute.bench.labelaudit # 3.2 정답표 감사
```

위 명령 중 수치를 내는 일곱(perfcard · calibrate 둘 · prereg · fairful · fragility · labelaudit)은 공개 사본을 새 폴더에 풀어 그대로 돌려 확인했다(LLM 0회). 회귀 시험(py -m bioreroute.tests.test_phase2)과 전 과정 점검(py -m bioreroute.bench.preflight --strict)은 작업 저장소를 기준으로 잴다 — 발표 생성기 · 실행 스크립트 · 배포 사본을 보는 항목이 있어 공개 사본에서는 그 항목이 실패로 뜬다. 회귀 시험 2661건은 작업 저장소에서 센 수다(시험정보.json).

- **코드** — 공개 저장소(머리의 주소 · 제출 시점 사본)에 배포 묶음 bioreroute-v69.zip(코드 · 문서 · 봉인 명세 · 결과 파일)의 내용(개발 중 작업 문서 넷은 뺐다 — 공개 README 에 목록)과, 판정 원본인 상태 파일(한 개 10 MB 안팎) · 봉인 해시의 제3자 타임스탬프(봉인해시_공개등록.txt.ots)가 들어 있다. **캐시는 넣지 않는다** — 넣으면 캐시가 자료원이 되는 사고가 되풀이된다. 그래서 캐시 없이 판정 경로를 다시 돌리면 그사이 바뀐 문헌과 LLM 답 때문에 입력과 판정이 달라질 수 있다 — 공개 사본으로 그대로 재현되는 것은 **상태 파일에서 수치를 다시 내는 것**까지다
- **모든 수치는 결과 파일에서 코드가 낸다.** 문서에 옮긴 수는 문서 감사가가 정본과 대조한다
- **자료는 전부 공개 · 무료다.** 회귀 시험 2661건 · 결함 대장 · 사전명세와 봉인 파일 · 실행 매뉴얼(재현절차.md)이 함께 있다

10. 맺음

이 프로젝트가 만든 것은 후보를 잘 고르는 모델이 아니라 **틀렸을 때 그것을 알아채는 절차**다. 그 절차가 우리 자신을 막은 순간을 셋만 꼽는다.

1. 홀드아웃 주지표가 미달했을 때 **기준을 고치지 않았다**(§4.3 · §4.4)
2. 유의한 값이 나왔을 때 사전 지정한 균형 부분집합에서 사라지는 것을 보고 **주장하지 않았다**(§4.9)
3. 헤드라인 지표에 모델 단독 기준선을 나란히 놓자 **우리가 졌다** — 그 표를 성능 절 맨 위에 둔다(§4.1)

본선 모델로 켜 774쌍에서 이 시스템이 기각한 것의 94.3%는 효능 실패로 중단된 시험의 약이었고(근거로 한 기각만 봐도 $66/70 = 94.3\%$), 성공한 약을 버린 것은 1.6%였다. 사전 지정 주지표는 미달했고

모델 기억을 넘어서지는 못했다. 남은 것은 판정마다 원문과 대조한 근거가 붙는다는 것, 그리고 모델이 모르는 곳에서도 근거로 기각한 16건 중 15건이 맞았다는 방향이다 (사후 · 표본이 작다 · §4.1).

우리가 남긴 것은 성능 수치가 아니라 **그 수치를 믿지 않는 방법**이다.

참고 문헌

1. Wong CH, Siah KW, Lo AW. Estimation of clinical trial success rates and related parameters. *Biostatistics* 2019;20(2):273–286.
2. Harrison RK. Phase II and phase III failures: 2013–2015. *Nat Rev Drug Discov* 2016;15(12):817–818.
3. Yogendrakumar V, Dewar B, McGuinty M, et al. Many trials of hydroxychloroquine for SARS-CoV-2 were redundant and potentially unethical: an analysis of the NIH clinical trials registry. *J Clin Epidemiol* 2022;143:73–80. doi:10.1016/j.jclinepi.2021.11.011
4. Maziarz M, Stencel A. The failure of drug repurposing for COVID-19 as an effect of excessive hypothesis testing and weak mechanistic evidence. *Hist Philos Life Sci* 2022;44(4):47. doi:10.1007/s40656-022-00532-9
5. Morselli Gysi D, do Valle Í, Zitnik M, et al. Network medicine framework for identifying drug-repurposing opportunities for COVID-19. *Proc Natl Acad Sci USA* 2021;118(19):e2025581118. doi:10.1073/pnas.2025581118
6. Pushpakom S, Iorio F, Eyers PA, et al. Drug repurposing: progress, challenges and recommendations. *Nat Rev Drug Discov* 2019;18(1):41–58.
7. RareAgent: Self-Evolving Reasoning for Drug Repurposing in Rare Diseases. arXiv:2510.05764 (2025).
8. Guney E. Reproducible drug repurposing: when similarity does not suffice. *Pac Symp Biocomput* 2017;22:132–143.
9. CiteCheck: Retrieval-Grounded Detection of LLM Citation Hallucinations. arXiv:2605.27700.
10. Scardino V, Di Filippo JJ, Cavasotto CN. How good are AlphaFold models for docking-based virtual screening? *iScience* 2023;26(1):105920. doi:10.1016/j.isci.2022.105920
11. Platt JC. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: *Advances in Large Margin Classifiers*. MIT Press; 1999:61–74.
12. Walsh M, Srinathan SK, McAuley DF, et al. The statistical significance of randomized controlled trial results is frequently fragile: a case for a Fragility Index. *J Clin Epidemiol* 2014;67(6):622–628.
13. Baell JB, Nissink JWM. Seven year itch: pan-assay interference compounds (PAINS) in 2017 — utility and limitations. *ACS Chem Biol* 2018;13(1):36–44.
14. Lipinski CA, Lombardo F, Dominy BW, Feeney PJ. Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings. *Adv Drug Deliv Rev* 2001;46(1–3):3–26.

15. Jumper J, Evans R, Pritzel A, et al. Highly accurate protein structure prediction with AlphaFold. *Nature* 2021;596:583–589.
16. Rena G, Hardie DG, Pearson ER. The mechanisms of action of metformin. *Diabetologia* 2017;60(9):1577–1585.
17. Brown AS, Patel CJ. A standard database for drug repositioning. *Sci Data* 2017;4:170029.
18. CiteGuard: Faithful Citation Attribution for LLMs via Retrieval-Augmented Validation. arXiv:2510.17853.
19. Swanson DR. Fish oil, Raynaud's syndrome, and undiscovered public knowledge. *Perspect Biol Med* 1986;30(1):7–18.
20. Guyatt GH, Oxman AD, Vist G, et al. GRADE guidelines: 4. Rating the quality of evidence — study limitations (risk of bias). *J Clin Epidemiol* 2011;64(4):407–415. doi:10.1016/j.jclinepi.2010.07.017
21. Mitigating LLM-based p-Hacking by Preregistering for the Next LLM. arXiv:2606.27687.
22. Predicting LLM Safety Before Release (OSF 사전등록 osf.io/un3he). arXiv:2607.07184.
23. Mallen A, Asai A, Zhong V, Das R, Khashabi D, Hajishirzi H. When not to trust language models: investigating effectiveness of parametric and non-parametric memories. In: *Proceedings of ACL 2023*. arXiv:2212.10511.